

شارة عالم البيانات · مرجع دراسي

الدليل المرجعي لعلم البيانات

المفاهيم والقرارات والأخطاء الشائعة للاستعداد لاختبار شارة عالم البيانات

TP	FP
FN	TN

إعداد

احمد الحربي

a-2011a@hotmail.com

الإصدار الأول · سبتمبر 2026

مرجع دراسي مستقل، وليس إصداراً رسمياً لأي جهة اختبار.

المحتويات

0	الأساسيات	3	7	التجميع (Ensembles) والبيانات غير المتوازنة	24
0.1	ما علم البيانات؟	3		24	24
0.2	أساسيات البيانات	3		24	24
0.3	ما نتعلم الآلي؟	4		24	24
0.4	الرياضيات التي تحتاجها	4		24	24
0.5	كيف يتعلم النموذج: مثال بسيط	5	8	التعلم غير الموجّه	25
0.6	أدوات Python	5		26	26
0.7	مشروع مصغر كامل	6		26	26
0.8	مسار الدراسة المقترح	7		26	26
1	سير عمل علم البيانات	8	9	السلاسل الزمنية والنصوص وأنظمة التوصية والتعلم العميق	27
1.1	دورة حياة المشروع (CRISP-DM)	8		27	27
1.2	صياغة مشكلة الأعمال كمهمة تعلم آلي	8		27	27
1.3	هل نحتاج إلى التعلم الآلي أصلاً؟	9		27	27
2	أسس الإحصاء	9	10	تقييم نماذج التصنيف	29
2.1	وصف البيانات	10		29	29
2.2	التوزيعات الشائعة	10		29	29
2.3	المعابنة والتحيز	11		29	29
2.4	مبرهنة النهاية المركزية والخطأ المعياري	11		29	29
2.5	فترات الثقة	11		30	30
2.6	الارتباط والسببية	11		30	30
2.7	الاحتمالات ومبرهنة بايز	12		30	30
3	اختبار الفرضيات واختبارات A/B	13	11	مقاييس الانحدار وتصميم التحقق	32
3.1	منطق الاختبار	13		32	32
3.2	الأخطاء وقوة الاختبار	13		32	32
3.3	اختبار الاختبار	13		32	32
3.4	اختبارات A/B	13		32	32
3.5	إيصال الرؤى	14		33	33
4	استكشاف البيانات وتنظيفها	15	12	تعلم الآلة في الإنتاج (MLOps)	33
4.1	قائمة تحقق عملية لتحليل EDA	15		34	34
4.2	البيانات المفقودة	15		34	34
4.3	القيم الشاذة	16		34	34
4.4	تحويل المتغيرات المطلوبة	16		34	34
4.5	مشكلات جودة البيانات	17		34	34
5	هندسة الميزات والمعالجة المسبقة	18	13	الذكاء الاصطناعي المسؤول	36
5.1	ترميز المتغيرات الفئوية	18		36	36
5.2	تجميع الميزات	18		36	36
5.3	Pipelines وتسرب المعالجة المسبقة	18		36	36
5.4	إنشاء ميزات مفيدة	19		36	36
5.5	التعدد الخطي	19		36	36
5.6	اختيار الميزات	20		36	36
6	نماذج التعلم الموجّه	20	14	جداول القرار السريع	37
6.1	المفاضلة بين الانحياز والتباين (Bias-Variance Trade-off)	21		37	37
6.2	الانحدار الخطي (Linear Regression)	21		37	37
6.3	الانحدار اللوجستي (Logistic Regression)	21		37	37
6.4	التنظيم (Regularization)	22		38	38
6.5	أشجار القرار (Decision Trees)	22		38	38
6.6	نماذج كلاسيكية أخرى	22		38	38
6.7	اختيار النموذج في ظل القيود	23		38	38
6.8	ضبط المعاملات الفائقة (Hyperparameter Tuning)	23	15	استراتيجية الاختبار	39
			16	مسرد المصطلحات	40

هذا الفصل لمن يبدأ من الصفر. يشرح الأفكار التي تفترض الفصول اللاحقة أنك تعرفها: ما البيانات وما النماذج، وكيف يتعلم النموذج، والحد الأدنى من الرياضيات، وأدوات Python المستخدمة عمليًا. إن كانت هذه الأفكار مألوفة لك، فانتقل مباشرة إلى الفصل 1.

0.1 ما علم البيانات؟

علم البيانات (Data science) يحوّل البيانات إلى قرارات. وهو يجمع ثلاث مهارات: **الإحصاء (statistics)** للتفكير السليم في ظل عدم اليقين، و**البرمجة (programming)** للتعامل مع البيانات بأحجام كبيرة، و**المعرفة بالمجال (domain knowledge)** لمعرفة الأسئلة التي تستحق الاهتمام.

الدور	السؤال الرئيسي	العمل المعتاد
محلل البيانات (Data analyst)	ماذا حدث؟ ولماذا؟	SQL، ولوحات المعلومات (dashboards)، والتقارير، والإحصاء الوصفي
عالم البيانات (Data scientist)	ماذا سيحدث؟ وماذا ينبغي أن نفعل؟	التجارب، والنماذج التنبؤية، ورؤى تدعم القرارات
مهندس التعلم الآلي (Machine learning engineer)	كيف نشغل النماذج بموثوقية في بيئة الإنتاج (production)؟	ال Pipelines، والنشر (deployment)، والمراقبة (monitoring)، والتوسع (scaling)
مهندس البيانات (Data engineer)	كيف تصل البيانات النظيفة إلى الجميع في الوقت المناسب؟	خطوط البيانات (data pipelines)، ومستودعات البيانات (warehouses)، وجودة البيانات

0.2 أساسيات البيانات

تبدأ معظم المشاريع ببيانات **جدولية (tabular data)**: جدول يمثل فيه كل صف (row) مشاهدة واحدة (عميلًا، أو طلبًا، أو يومًا)، ويمثل كل عمود (column) متغيرًا واحدًا.

نوع البيانات	المعنى	أمثلة
رقمية: متصلة (continuous)	أي قيمة ضمن نطاق	السعر، ودرجة الحرارة، ومدة التوصيل
رقمية: منفصلة (discrete)	أعداد صحيحة قابلة للعدّ	عدد الطلبات، أو الأطفال، أو الزيارات
فئوية: اسمية (nominal)	تسميات بلا ترتيب	المدينة، وطريقة الدفع، ونوع المنتج
فئوية: ترتيبية (ordinal)	تسميات لها ترتيب طبيعي	الرضا (منخفض / متوسط / مرتفع)، والمستوى التعليمي
التاريخ والوقت	لحظة أو فترة زمنية	وقت تسجيل الطلب (timestamp)، وتاريخ التسجيل
نصوص، وصور، وصوت	بيانات غير منظّمة (unstructured)	المراجعات، وصور الأشعة السينية، وتسجيلات المكالمات

- **الخاصية (Feature)** (وتُسمى أيضًا المُدخل، أو المتغير المستقل، أو X): معلومة يستخدمها النموذج في التنبؤ.
- **المتغير المستهدف (Target)** (وتُسمى أيضًا التسمية label، أو المتغير التابع، أو y): القيمة التي نريد التنبؤ بها.
- **مستوى التفصيل (Grain)**: ما الذي يمثله الصف الواحد. تأكد منه دائمًا قبل التحليل، لأن خلط مستويات مختلفة (عملاء وطلبات في جدول واحد) يؤدي إلى مجاميع خاطئة.
- **البيانات المنظّمة (Structured data)** تناسب الصفوف والأعمدة. أما **البيانات غير المنظّمة (Unstructured data)** (النصوص والصور) فحتاج إلى معالجة إضافية قبل أن تستخدمها معظم النماذج.

0.3 ما التعلّم الآلي؟

في البرمجة التقليدية يكتب الإنسان القواعد بنفسه. أما في التعلّم الآلي (machine learning) فيتعلّم الحاسوب القواعد من الأمثلة: تعطيه مُدخلات (X) مع إجاباتها المعروفة (y)، فيجد دالة f بحيث $f(X) \approx y$ على بيانات جديدة لم يرها من قبل.

النوع	البيانات	الهدف	مثال
تعلّم موجّه (Supervised): تصنيف (classification)	بيانات لها تسميات، والمتغير المستهدف فئة	التنبؤ بفئة	هل سيغادر هذا العميل (churn)؟ (نعم / لا)
تعلّم موجّه (Supervised): انحدار (regression)	بيانات لها تسميات، والمتغير المستهدف رقم	التنبؤ بكمية	بكم سيُباع هذا المنزل؟
تعلّم غير موجّه (Unsupervised)	بلا تسميات	اكتشاف بنية في البيانات	تقسيم العملاء إلى شرائح (segments)
التعلّم المعزّز (Reinforcement learning)	مكافآت ناتجة عن الأفعال	تعلّم استراتيجية	روبوت أو وكيل (agent) في لعبة يتعلّم بالتجربة والخطأ

- المعاملات (Parameters) يتعلّمها النموذج من البيانات أثناء التدريب (مثل أوزان النموذج الخطي).
- المعاملات الفائقة (Hyperparameters) تختارها أنت قبل التدريب (مثل عمق الشجرة، ومعدّل التعلّم learning rate).
- التدريب (Training) يعني تعديل المعاملات لجعل أخطاء التنبؤ أصغر ما يمكن، وتُقاس هذه الأخطاء بدالة الخسارة (loss function).
- التعميم (Generalization) هو الهدف الحقيقي: أداء جيد على بيانات جديدة، لا على البيانات التي حفظها النموذج.

القاعدة الذهبية

لا تحكم أبدًا على نموذج من خلال البيانات التي تدرب عليها. احتفظ بمجموعة اختبار (test set) منفصلة (مثلًا 20% من الصفوف)، ولا تستخدمها إلا للفحص النهائي.

0.4 الرياضيات التي تحتاجها

الإحصاء الوصفي (Descriptive statistics). للقيم 2, 4, 4, 4, 5, 5, 7, 9:

مثال محلول

mean = $40 / 8 = 5$ · squared deviations: 9, 1, 1, 1, 0, 0, 4, 16 → sum = 32

variance (population) = $32 / 8 = 4$ · standard deviation = $\sqrt{4} = 2$

أما تباين العينة (sample variance) فيُقسّم على $n - 1$ بدلًا من ذلك: $32 / 7 \approx 4.57$ ، فيصبح الانحراف المعياري ≈ 2.14 . والوسيط (median)، أي القيمة الوسطى، هو $(4 + 5) / 2 = 4.5$.

الاحتمال (Probability). الاحتمال رقم بين 0 (مستحيل) و 1 (مؤكد).

- المُتمم (Complement): $P(\text{not } A) = 1 - P(A)$. إذا كان $P(\text{rain}) = 0.3$ ، فإن $P(\text{no rain}) = 0.7$.
- الأحداث المستقلة (Independent events): $P(A \text{ and } B) = P(A) \times P(B)$. احتمال أن تظهر «صورة» في رميَّ عمليتين متوازنتين معًا هو $0.5 \times 0.5 = 0.25$.
- الاحتمال الشرطي (Conditional probability): $P(A | B) = P(A \text{ and } B) / P(B)$. أي احتمال A بشرط وقوع B. إذا كان 30 من كل 100 عميل من فئة premium، وغادر 12 منهم، فإن $P(\text{churn} | \text{premium}) = 12 / 30 = 0.4$.

المتجهات والمصفوفات (Vectors and matrices). المتجه (vector) قائمة مرتبة من الأرقام، مثل خصائص عميل واحد. والمصفوفة (matrix) جدول من الأرقام. ومجموعة بيانات فيها n صف و p خاصية هي مصفوفة $n \times p$.

الضرب النقطي والنموذج الخطي

$$[2, 3] \cdot [4, 1] = 2 \times 4 + 3 \times 1 = 11$$

$$\text{price} = w \cdot x + b = [3, 20] \cdot [120, 3] + 50 = 360 + 60 + 50 = 470$$

هنا $x = (120 \text{ m}^2, 3)$ أي المساحة 120 م² وعدد الغرف 3، والأوزان w تبين مقدار ما تضيفه كل خاصية، و b هو الحد الثابت (intercept). فالنموذج الخطي ما هو إلا ضرب نقطي (dot product) مضافاً إليه ثابت.

المشتقات والانحدار التدريجي (Derivatives and gradient descent). المشتقة تقيس الميل: أي مدى سرعة تغير الدالة. وتدريب النموذج يعني إيجاد قيم المعاملات التي تكون عندها الخسارة في أدنى مستوى، والانحدار التدريجي (gradient descent) يصل إلى ذلك بأخذ خطوات صغيرة متكررة نحو الأسفل.

خطوة الانحدار التدريجي

$$w \leftarrow w - \eta \cdot dL/dw \quad (\eta = \text{learning rate})$$

مثال: $L(w) = (w - 3)^2$ ، إذن $dL/dw = 2(w - 3)$. نبدأ من $w = 0$ مع $\eta = 0.1$: قيمة التدرج (gradient) هي -6، فتصبح w مساوية 0.6؛ ثم يكون التدرج التالي -4.8، فتصبح w مساوية 1.08؛ وتستمر الخطوات في التناقص كلما اقتربت w من القيمة الدنيا عند 3.

اللوغاريتمات والدوال الأسية (Logarithms and exponentials). اللوغاريتم log يضغط الأرقام الكبيرة $\log_{10}(1,000) = 3$ ، ولهذا يُستخدم تحويل log لترويض البيانات الملتوية (skewed) مثل الدخل. أما الدالة الأسية e^x فهي معكوسة، وتظهر في الانحدار اللوجستي (logistic regression) وفي عمليات النمو أو التناقص.

0.5 كيف يتعلم النموذج: مثال بسيط

لنفترض أننا ننتبأ بمدة التوصل (بالدقائق) من المسافة (بالكيلومتر) باستخدام خط مستقيم: $\text{time} = w \times \text{distance} + b$.

1. ابدأ بقيم عشوائية لـ w و b.
2. تنبأ بمدة التوصل لكل طلب في بيانات التدريب.
3. قس الخطأ بدالة خسارة، مثل متوسط مربع الخطأ (mean squared error): متوسط $(\text{actual} - \text{predicted})^2$.
4. عدّل w و b في الاتجاه الذي يقلّل الخسارة (الانحدار التدريجي).
5. كرّر حتى تتوقف الخسارة عن التحسّن.
6. قيّم الخط النهائي على مجموعة الاختبار.

كل نموذج في هذا الدليل، من الانحدار اللوجستي إلى الشبكات العصبية (neural networks)، يتبع هذه الحلقة نفسها. الذي يتغير هو شكل الدالة، والخسارة التي نسعى إلى تقليلها.

0.6 أدوات Python

المكتبة	الاستخدام
NumPy	مصفوفات (arrays) سريعة وعمليات رياضية
pandas	تحميل الجداول (DataFrames) وتنظيفها ودمجها وتلخيصها
Matplotlib / seaborn	رسوم بيانية للاستكشاف وإعداد التقارير

المكتبة	الاستخدام
scikit-learn	المعالجة المسبقة (preprocessing)، والنماذج الكلاسيكية، والتقييم، و Pipelines
XGBoost / LightGBM	التعزيز التدريجي (gradient boosting) للبيانات الجدولية
PyTorch / TensorFlow	التعلم العميق (deep learning)

عمليات pandas اليومية

```
import pandas as pd
df = pd.read_csv("customers.csv")      # load a table
df.head()                             # first rows
df.info()                             # column types and non-null counts
df.describe()                         # summary statistics for numeric columns
df.isna().sum()                       # missing values per column
df["city"].value_counts()             # frequency of each category
df.groupby("city")["spend"].mean()    # average spend per city
df = df.merge(orders, on="customer_id", how="left") # join two tables
```

نمط scikit-learn. تتبع كل الكائنات تقريبًا الواجهة نفسها:

- `fit(X, y)` يتعلم من بيانات التدريب.
- `predict(X)` أو `predict_proba(X)` يُنتج التنبؤات.
- `transform(X)` يطبق خطوة معالجة مسبقة تم تعلمها (مثل التحجيم `scaling`، والترميز `encoding`).

0.7 مشروع مصغر كامل

الهدف: التنبؤ بعملاء شركة الاتصالات الذين سيغادرون (`churn`)، ليتصل بهم فريق الاحتفاظ بالعملاء أولاً.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, roc_auc_score

df = pd.read_csv("churn.csv")
X, y = df.drop(columns=["customer_id", "churn"], df["churn"]

# 1. hold out a test set, keeping the churn rate equal in both parts
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

# 2. preprocessing for each column type
num = ["tenure_months", "monthly_charge", "support_calls"]
cat = ["contract_type", "payment_method"]
prep = ColumnTransformer([
    ("num", Pipeline([("impute", SimpleImputer(strategy="median")),
                     ("scale", StandardScaler())]), num),
    ("cat", OneHotEncoder(handle_unknown="ignore"), cat)])
```

```
# 3. one pipeline = preprocessing + model, fitted on training data only
model = Pipeline([("prep", prep),
                  ("clf", LogisticRegression(class_weight="balanced", max_iter=1000))])
model.fit(X_train, y_train)

# 4. evaluate on data the model has never seen
proba = model.predict_proba(X_test)[:, 1]
print(classification_report(y_test, model.predict(X_test)))
print("ROC-AUC:", round(roc_auc_score(y_test, proba), 3))
```

الخطوة	لماذا هي مهمة	للمزيد
تحديد الهدف والتسمية (label)	يجب أن تكون «المغادرة» قابلة للقياس، وأن يقود التنبؤ إلى إجراء عملي	الفصل 1
تقسيم طبقي (Stratified) إلى train/test	تقييم نزبه بنفس توازن الفئات في الجزأين	الفصل 11
التعويض (Imputation) والتجيم والترميز داخل Pipeline	يجب أن البيانات دون تسريب (leakage) معلومات من مجموعة الاختبار	الفصلان 4-5
نموذج أساس (baseline) بسيط وقابل للتفسير	يضع المستوى الذي يجب أن تتفوق عليه النماذج الأعقد	الفصل 6
class_weight="balanced"	العملاء المغادرون هم الفئة الأقل عدداً (minority class)	الفصل 7
الدقة (Precision)، والاستدعاء (Recall)، و ROC-AUC	الصحة الإجمالية (Accuracy) مضللة عندما تكون الفئات غير متوازنة	الفصل 10

الخطوات التالية في مشروع حقيقي: جرّب نموذجاً أقوى (الغابة العشوائية random forest، أو التعزيز التدريجي gradient boosting) مع التحقق المتقاطع (cross-validation)، واختر عتبة القرار (threshold) بناءً على تكلفة المكالمات مقابل تكلفة خسارة العملاء، وشرح لقطاع الأعمال العوامل التي تدفع العملاء إلى المغادرة، ثم انشر النموذج وراقبه.

0.8 مسار الدراسة المقترح

إذا كنت...	اقرأ بهذا الترتيب
مبتدئاً تماماً	الفصل 11 ← 10 ← 6 ← 5 ← 4 ← 2 ← 0، ثم البقية
متمكناً من Python وجديداً على التعلم الآلي	الفصول 12 ← 11 ← 10 ← 7 ← 6 ← 5 ← 4 ← 1
تراجع قبل الاختبار مباشرة	الفصل 14 (أوراق القرار)، ثم 15 (الاستراتيجية)، ثم مربعات «فخ شائع» في كل فصل

تعلم بالممارسة

القراءة وحدها لا تكفي. افتح دفتر Jupyter، وحمل مجموعة بيانات عامة (Titanic من Kaggle أو مجموعة بيانات لمغادرة عملاء الاتصالات)، وأعد تنفيذ المشروع المصغر أعلاه. ثم غير شيئاً واحداً في كل مرة، ولاحظ كيف تتغير المقاييس.

1 سير عمل علم البيانات

يفشل معظم المشاريع قبل تدريب أي نموذج: سؤال خاطئ، أو تسمية (label) خاطئة، أو مقياس نجاح لم يتفق عليه أحد. لذلك يبذل عالم البيانات الجيد جهدًا حقيقيًا في صياغة المشكلة (framing).

1.1 دورة حياة المشروع (CRISP-DM)

CRISP-DM هو نموذج العمليات الأوسع استخدامًا. وهو نموذج تكراري (iterative)؛ فالمرحل اللاحقة كثيرًا ما تعيدك إلى مراحل سابقة.

المرحلة	السؤال الرئيسي	المخرجات المعتادة
فهم الأعمال (Business understanding)	ما القرار الذي سيدعمه المشروع؟ وكيف سنقيس النجاح؟	الهدف، ومؤشر الأداء (KPI)، والقيود، وعتبة النجاح
فهم البيانات (Data understanding)	ما البيانات المتاحة؟ وما جودتها؟ وهل المتغير المستهدف (target) متوفر؟	جرد البيانات، وتقرير الجودة، وتحليل استكشافي (EDA) أولي
تجهيز البيانات (Data preparation)	كيف نحول البيانات الخام إلى جدول صالح للنمذجة؟	خصائص (features) منطّفة، وتسميات، وتقسيمات train/validation/test
النمذجة (Modelling)	أي منهج يحل المهمة ضمن القيود؟	نموذج أساس (Baseline)، ونماذج مرشّحة، ونموذج مضبوط (tuned)
التقييم (Evaluation)	هل يحقق هدف الأعمال، لا المقياس فقط؟	نتائج الاختبار، وتحليل الأخطاء، وقرار المضي أو التوقف (go/no-go)
النشر (Deployment)	كيف يُستخدم النموذج ويُراقب ويُصان؟	خدمة أو مهمة دفعية (batch job)، ومراقبة، وخطة إعادة تدريب

نصيحة للاختبار

عندما يسأل السؤال عما يجب فعله أولاً، فالإجابة غالبًا تتعلق بفهم المشكلة أو البيانات (توضيح الهدف، والتحقق من توفر التسميات، وفحص جودة البيانات)، لا باختيار خوارزمية.

1.2 صياغة مشكلة الأعمال كمهمة تعلّم آلي

طلب الأعمال	الصياغة في التعلّم الآلي	المتغير المستهدف / المخرج المعتاد
أي العملاء سيفادرون الشهر القادم؟	تصنيف ثنائي (Binary classification)	churn = 1 / 0 ضمن أفق زمني محدد
كم وحدة سنبيع في كل متجر أسبوعيًا؟	انحدار / (Regression) تنبؤ بالسلاسل الزمنية (time-series forecasting)	كمية رقمية
تجميع العملاء ذوي السلوك المتشابه	التجميع (Clustering)، وهو غير خاضع للإشراف (unsupervised)	معزف الشريحة (Segment ID)
رصد المعاملات غير المعتادة مع قلة الحالات المُسّقة	كشف الشذوذ (Anomaly detection)، أو التصنيف إن توفرت التسميات	درجة الشذوذ (Anomaly score)
أي المنتجات نعرضها أولاً لكل مستخدم؟	الترتيب / (Ranking) التوصية (recommendation)	قائمة مرتّبة

طلب الأعمال	الصياغة في التعلّم الآلي	المتغير المستهدف / المخرج المعتاد
إلى أي فئة من فئات التذاكر الخمس تنتمي هذه الشكوى؟	تصنيف متعدد الفئات (Multi-class classification)	فئة واحدة من K فئة

- **عرّف التسمية بدقة:** يجب أن تعني كلمة «غادر» (churned) شيئاً قابلاً للقياس (مثل انعدام النشاط 30 يومًا)، مع أفق تنبؤ واضح.
- **استخدم فقط المعلومات المتاحة وقت التنبؤ.** الخاصية التي تُنشأ بعد وقوع النتيجة تسبب تسرب المتغير المستهدف (target leakage).
- **اربط مقياس النموذج بمؤشر أداء الأعمال (KPI).** الاستدعاء (Recall) لحالات الاحتيال مهم لأن كل احتيال فائت يكلف مالاً.
- **ابدأ بنموذج أساس (baseline):** قاعدة بسيطة، أو الفئة الأغلب (majority class)، أو قيمة الفترة السابقة. يجب أن يتفوق النموذج عليه ليستحق النشر.

1.3 هل نحتاج إلى التعلّم الآلي أصلاً؟

يكون التعلّم الآلي مبرّراً حين يكون النمط أعقد من أن تصفه قواعد صريحة، وتتوفر بيانات تاريخية كافية وذات صلة، ويكون النمط مستقرّاً إلى حد معقول، وتكون الأخطاء محتملة أو قابلة للمراجعة. فضّل القواعد أو SQL أو لوحة المعلومات (dashboard) حين يكون المنطق بسيطاً ومعروفاً، أو البيانات قليلة، أو حين يُشترط قرار حتمي (deterministic) شفاف بالكامل.

فخ شائع

اختبار نموذج معقد قبل التأكد من أن قاعدة بسيطة أو نموذج أساس لا يحل المشكلة بالفعل. أفضل إجابة كثيراً ما تبدأ بتحديد نطاق منتج أولي صغير (MVP).

يتيح لك الإحصاء وصف البيانات بأمانة، وقياس عدم اليقين، وتجنب الانخداع بالضوضاء (noise).

2.1 وصف البيانات

المقياس	ماذا يصف	متى نفضله
المتوسط الحسابي (Mean)	المعدل الحسابي	البيانات المتماثلة الخالية من القيم المتطرفة
الوسيط (Median)	القيمة الوسطى (المئين 50)	البيانات الملتوية أو ذات القيم الشاذة (الدخل، أسعار المنازل، أزمنة التوصيل)
المودال (Mode)	القيمة الأكثر تكرارًا	البيانات الفئوية (Categorical)
الانحراف المعياري (Standard deviation)	المسافة المعتادة عن المتوسط	البيانات المتماثلة تقريبًا
المدى الربيعي IQR (Q3 - Q1)	انتشار الـ 50% الوسطى	البيانات الملتوية؛ وهو مقاوم (robust) للقيم الشاذة
المئينات (Percentiles)	القيمة التي يقع تحتها %p من البيانات	مستويات الخدمة (مثل زمن الاستجابة عند المئين 95)

- **الالتواء الأيمن أو الموجب (Right / positive skew):** ذيل طويل جهة اليمين، وعادةً $\text{mean} > \text{median}$ (الدخل، مبالغ المعاملات).
- **الالتواء الأيسر أو السالب (Left / negative skew):** ذيل طويل جهة اليسار، وعادةً $\text{mean} < \text{median}$.
- **ثنائي المنوال (Bimodal):** قمتان، وكثيرًا ما يدل ذلك على مجتمعين فرعيين مختلفين ينبغي تحليل كلٍّ منهما على حدة.

2.2 التوزيعات الشائعة

التوزيع	ماذا يمثّل	مثال
الطبيعي (Normal)	مجموع تأثيرات صغيرة كثيرة؛ شكل جرس متماثل	خطأ القياس، الأطوال
ذو الحدين (Binomial)	عدد النجاحات في n محاولة مستقلة بنتيجة نعم/لا	عدد التحويلات من بين 1,000 زائر
بواسون (Poisson)	عدد الأحداث في فترة ثابتة بمعدل ثابت	المكالمات في الساعة، العيوب في كل دفعة
الأُسّي (Exponential)	زمن الانتظار بين أحداث بواسون	الوقت حتى الوصول التالي
طويل الذيل / اللوغاريتمي الطبيعي (Long-tailed / log-normal)	قيم صغيرة كثيرة وقيم كبيرة جدًا قليلة	الإيراد لكل عميل، أحجام الملفات

قاعدة تقريبية للتوزيع الطبيعي

$\approx 68\%$ within $\pm 1\sigma$ • $\approx 95\%$ within $\pm 2\sigma$ • $\approx 99.7\%$ within $\pm 3\sigma$

2.3 المعاينة والتحيز

- **المعاينة العشوائية البسيطة (Simple random sampling):** لكل وحدة فرصة متساوية في الاختيار.
- **المعاينة الطبقية (Stratified sampling):** السحب داخل مجموعات (طبقات، strata) لضمان تمثيل كل مجموعة. وهي ضرورية للمجموعات النادرة.
- **المعاينة العنقودية (Cluster sampling):** اختيار مجموعات كاملة عشوائيًا (مثل الفروع)، ثم ملاحظة كل من بداخلها. أقل تكلفة لكنها أقل دقة.
- **المعاينة الملائمة (Convenience sampling):** اختيار من يسهل الوصول إليهم. وهي عرضة للتحيز.

التحيز	ما الخلل
تحيز الاختيار (Selection bias)	تختلف العينة اختلافاً منهجياً عن المجتمع (مثل استطلاع مستخدمي التطبيق فقط)
تحيز البقاء (Survivorship bias)	لا يُلاحظ إلا «الناجون» (مثل تحليل الشركات التي لا تزال تعمل فقط)
تحيز عدم الاستجابة (Non-response bias)	من يستجيبون يختلفون عمقاً لا يستجيبون
تحيز القياس (Measurement bias)	أداة القياس أو عملية تشوّه القيم

2.4 مبرهنة النهاية المركزية والخطأ المعياري

تنص **مبرهنة النهاية المركزية (Central limit theorem)** على أن توزيع متوسط العينة يكون طبيعيًا تقريبًا عندما تكون العينات كبيرة بما يكفي، أيًا كان شكل البيانات الأصلية. ولهذا تنجح فترات الثقة وكثير من الاختبارات.

الخطأ المعياري للمتوسط (Standard error of the mean)

$$SE = \sigma / \sqrt{n}$$

مضاعفة حجم العينة أربع مرات تُنصّف الخطأ المعياري.

2.5 فترات الثقة

فترة الثقة (Confidence interval) بمستوى 95% تُنتجها إجراءات تلتقط المعلمة الحقيقية في 95% من العينات المتكررة.

فترة ثقة تقريبية بمستوى 95% للمتوسط

$$\bar{x} \pm 1.96 \times SE$$

- العينة الأكبر تعطي فترة أضيق، ومستوى الثقة الأعلى يعطي فترة أوسع.
- إذا لم تتضمن فترة الثقة 95% لفرق ما القيمة 0، فالفرق دال إحصائيًا عند $\alpha = 0.05$.

فخ شائع

عبارة «هناك احتمال 95% أن القيمة الحقيقية تقع في هذه الفترة بعينها» ليست التفسير التكراري (frequentist). فال 95% تصف سلوك الإجراء على المدى الطويل.

2.6 الارتباط والسببية

- **ارتباط بيرسون (Pearson correlation)** يقيس العلاقة الخطية، وهو حساس للقيم الشاذة.

- **ارتباط سبيرمان (Spearman correlation)** يقيس العلاقة الرتيبة (monotonic) باستخدام الرتب، لذا فهو مقاوم للقيم الشاذة وللعلاقات غير الخطية الرتيبة.
- الارتباط القريب من 0 لا يعني «انعدام العلاقة». فنمط قوي على شكل U قد يكون ارتباطه قريبًا من 0.
- **الارتباط ليس سببية.** قد يؤثر متغير مُربك (confounder) في المتغيرين معًا (مثل الطقس الحار الذي يرفع مبيعات الآيس كريم وحوادث الغرق معًا).
- لإثبات السببية، أجرِ تجربة عشوائية مضبوطة (randomized controlled experiment) متى أمكن.

مفارقة سيمبسون (Simpson's paradox)

قد ينعكس اتجاه يظهر في كل مجموعة فرعية عند دمج المجموعات، بسبب اختلاف أحجامها. مثال: مستشفى نسبة النجاة فيه أعلى في الحالات الخفيفة والشديدة كليهما، لكن نسبته الإجمالية أقل، لأنه يعالج حالات شديدة أكثر بكثير. تحقق دائمًا مما إذا كان متغير خفي (lurking variable) يغيّر تركيبة المجموعات.

الانحدار نحو المتوسط (Regression to the mean): تميل الملاحظات المتطرفة إلى أن تليها قيم أقرب إلى المعدل. فالفروع المختارة لأنها «الأسوأ أداءً» كثيرًا ما تتحسن في الربع التالي حتى دون أي تدخل.

2.7 الاحتمالات ومبرهنة بايز

مبرهنة بايز (Bayes' theorem)

$$P(A | B) = P(B | A) \cdot P(A) / P(B)$$

مثال المعدل الأساسي (Base-rate). مرض انتشاره 1%. حساسية الاختبار (sensitivity) 90% ونوعيته (specificity) 91%. من بين 10,000 شخص:

- 100 مريض ← 90 منهم نتيجتهم إيجابية (إيجابيات صحيحة، true positives).
- 9,900 سليم ← 9% منهم، أي 891، نتيجتهم إيجابية (إيجابيات كاذبة، false positives).
- $9.2\% \approx P(\text{sick} | \text{positive}) = 90 / (90 + 891)$

فخ شائع

الخلط بين الحساسية $P(\text{positive} | \text{sick})$ والقيمة التنبؤية الإيجابية (positive predictive value) $P(\text{sick} | \text{positive})$. حين تكون الحالة نادرة، قد تكون معظم النتائج الإيجابية كاذبة.

القيمة المتوقعة (Expected value) = $\Sigma (\text{outcome} \times \text{probability})$. تُستخدم لمقارنة القرارات في ظل عدم اليقين، مثل الربح المتوقع من التواصل مع عميل.

3 اختبار الفرضيات واختبارات A/B

3.1 منطق الاختبار

- الفرضية الصفرية (H_0 Null hypothesis): لا يوجد أثر أو فرق.
- الفرضية البديلة (H_1 Alternative hypothesis): يوجد أثر.
- القيمة الاحتمالية (p -value): احتمال مشاهدة بيانات متطرفة بهذا القدر على الأقل لو كانت H_0 صحيحة.
- مستوى الدلالة α (Significance level) (غالبًا 0.05): ارفض H_0 إذا كان $p < \alpha$.

ما ليس هو الـ p -value

- ليس احتمال أن تكون H_0 صحيحة.
- ليس حجم الأثر ولا أهميته.
- $p > 0.05$ لا يثبت انعدام الأثر؛ فقد تكون قوة الاختبار (power) غير كافية.

3.2 الأخطاء وقوة الاختبار

H_0 خاطئة	H_0 صحيحة
رفض H_0	خطأ من النوع الأول (Type I error) (إيجابي كاذب)، احتمال α
قرار صحيح ($\text{power} = 1 - \beta$)	
خطأ من النوع الثاني (Type II error) (سلي كاذب)، احتمال β	عدم الرفض
قرار صحيح	

قوة الاختبار (Power) تزداد بزيادة العينة، وكثير الأثر الحقيقي، وانخفاض التباين، وارتفاع α . استهدف قوة 80% عند تخطيط التجربة.

3.3 اختيار الاختبار

الحالة	الاختبار
مقارنة متوسطي مجموعتين مستقلتين	اختبار t لعينتين (Two-sample t -test)، واختبار Welch إذا اختلف التباين
مقارنة قياسين على الوحدات نفسها (قبل/بعد)	اختبار t المزدوج (Paired t -test)
مقارنة متوسطات 3 مجموعات أو أكثر	تحليل التباين (ANOVA)، ثم الاختبارات اللاحقة (post-hoc)
مجموعتان، وبيانات ملتوية أو مقياس ترتيبي (ordinal)	Mann-Whitney U (لا معلمي، non-parametric)
العلاقة بين متغيرين فئويين	اختبار مربع كاي للاستقلال (Chi-square test of independence)
مقارنة نسبتي (معدلات التحويل)	اختبار z لنسبتي (Two-proportion z -test)، أو مربع كاي

3.4 اختبارات A/B

- حدّد مقياسًا أساسيًا واحدًا (primary metric) ومقاييس حماية (guardrail metrics) مثل زمن الاستجابة والمبالغ المستردة، وذلك قبل البدء.
- اختر وحدة التوزيع العشوائي (randomization unit) (مستخدم، جلسة، متجر). التوزيع على مستوى المستخدم يمنع أن يرى الشخص الواحد النسختين.

3. احسب حجم العينة من المعدل الأساسي (baseline rate)، والحد الأدنى للأثر القابل للكشف (minimum detectable effect)، و α ، وقوة الاختبار.
4. شغل التجربة للمدة المخطط لها، وتكون دورات أسبوعية كاملة على الأقل، لتغطية أثر أيام الأسبوع.
5. حلل مرة واحدة في النهاية، وأبلغ عن حجم الأثر (effect size) مع فترة ثقة.

المزلق	لماذا يهم	العلاج
التلصص (Peeking) والإيقاف المبكر	يضخم الإيجابيات الكاذبة	أفق زمني ثابت، أو أساليب الاختبار المتتابع (sequential testing)
كثرة المقاييس أو الشرائح	عند $\alpha = 0.05$ يكون اختبار واحد من كل 20 «دالاً» بالصدفة	سجل مقياساً أساسياً مسبقاً؛ وصحح بطريقة Bonferroni (α/m) أو FDR
أثر الجدة (Novelty effect)	يتفاعل المستخدمون مع التغيير ذاته، ثم يتلاشى الأثر	أطل مدة التجربة؛ وتابع الأثر عبر الزمن
عدم تطابق نسبة العينة (Sample ratio mismatch)	التقسيم الملاحظ (مثل 52/48) يختلف عن المخطط (50/50)	تحقق من خلل الإسناد قبل الوثوق بالنتائج
آثار الشبكة أو التداخل (Network / interference effects)	مستخدمو المعالجة يؤثرون في مستخدمي المجموعة الضابطة	وزع عشوائياً على مستوى العقود (مدينة، مجموعة)

نصيحة للاختبار

الدلالة الإحصائية (Statistical significance) ليست هي الدلالة العملية (practical significance). فمع ملايين المستخدمين قد يكون تحسن ضئيل عديم القيمة تجارياً «دالاً». قارن حجم الأثر بتكلفة تنفيذ التغيير.

3.5 إيصال الرؤى

- ابدأ بالقرار أو التوصية، ثم الأدلة.
- أبلغ عن عدم اليقين (نطاقات، فترات ثقة)، لا عن التقديرات النقطية (point estimates) وحدها.
- اختر المخطط المناسب: المدرج التكراري (histogram) أو مخطط الصندوق (box plot) للتوزيع، والمخطط الخطي (line chart) للاتجاه عبر الزمن، والمخطط الشريطي (bar chart) لمقارنة الفئات، ومخطط الانتشار (scatter plot) للعلاقة بين متغيرين رقميين، والخريطة الحرارية (heatmap) لمصفوفة الارتباط.
- تجنب المراثيات المضللة: المحاور المقطوعة في المخططات الشريطية، والمحاور المزدوجة، والتأثيرات ثلاثية الأبعاد، والمقاييس غير المتسقة.

4 استكشاف البيانات وتنظيفها

يكشف لك تحليل البيانات الاستكشافي (Exploratory Data Analysis – EDA) ما تستطيع البيانات دعمه وما لا تستطيع. ويجب أن تكون قرارات التنظيف مبررة وموثقة وقابلة لإعادة الإنتاج (reproducible).

4.1 قائمة تحقق عملية لتحليل EDA

1. الحجم ومستوى التفصيل (Shape and grain): كم عدد الصفوف؟ وماذا يمثل الصف الواحد: عميلاً، أم معاملة، أم يوماً؟
2. الأنواع (Types): هل الأرقام مخزنة كنصوص؟ هل حُلَّت التواريخ (parsed)؟ هل تُعامل المعرفات (IDs) خطأً كقيم رقمية؟
3. القيم المفقودة (Missing values): نسبتها في كل عمود، وهل يرتبط غيابها بمتغيرات أخرى أو بالمتغير الهدف (target)؟
4. التوزيعات (Distributions): الالتواء (skew)، والقيم المستحيلة (عمر سالب)، والرموز البديلة (sentinel codes) مثل 999-99999.
5. التكرارات (Duplicates): التكرارات التامة، والتكرارات على مفتاح العمل (business key).
6. الهدف (Target): توازن الفئات (class balance)، أو توزيع الهدف الرقمي.
7. العلاقات (Relationships): الارتباطات (correlations)، ورسوم الميزة مقابل الهدف، والمجموعات التي تسلك سلوكاً مختلفاً.
8. الزمن (Time): مدى التغطية، والفجوات، وتغير التعريفات عبر الزمن.

فخ شائع

عمليات الربط (Joins) التي تضاعف الصفوف بصمت. إذا لم يكن مفتاح الربط فريداً في الجدول الأيمن، فإن LEFT JOIN يكرر الصفوف ويضخم المجاميع. تحقق من تفرد المفتاح قبل الربط.

4.2 البيانات المفقودة

الآلية	المعنى	مثال	الأثر
MCAR: مفقودة عشوائياً تماماً (missing completely at random)	الغياب لا يرتبط بأي متغير	عطل عشوائي في إرسال بيانات أحد الحساسات	الحذف غير متحيز (تخسر بيانات فقط)
MAR: مفقودة عشوائياً (missing at random)	الغياب يعتمد على متغيرات مرصودة	العملاء الأكبر سناً يتخطون حقل «تقييم التطبيق»	التعويض المعتمد على نموذج باستخدام تلك المتغيرات يعمل جيداً
MNAR: مفقودة غير عشوائياً (missing not at random)	الغياب يعتمد على القيمة المفقودة نفسها	أصحاب الدخل المرتفع يرفضون الإفصاح عن دخلهم	يصعب علاجها؛ أضف مؤشر غياب، أو اجمع بيانات، أو استعن بالمعرفة بالمجال
الاستراتيجية	متى تُستخدم	المخاطرة	
حذف الصفوف (listwise deletion)	عدد قليل من الصفوف متأثر والبيانات MCAR	فقدان بيانات؛ وتحتجز إن لم تكن MCAR	
حذف العمود	معظمه مفقود (مثلاً >80%) وقيمته قليلة	فقدان إشارة مفيدة إن كان الغياب نفسه يحمل معلومة	
التعويض بالمتوسط أو الوسيط (Mean or median imputation)	خط أساس بسيط؛ والوسيط للبيانات الملتوية	يقلص التباين ويشوه العلاقات	
النموال (Mode) أو فئة «Unknown»	الميزات الفئوية	قد ينشئ فئة اصطناعية كبيرة	

الاستراتيجية	مق يُستخدم	المخاطرة
تعويض KNN أو التعويض التكراري (iterative، معتمد على نموذج)	بيانات MAR مع ميزات مترابطة	أبطأ؛ ويجب ملاءمته (fit) على بيانات التدريب فقط
ميزة مؤشر الغياب (Missing indicator)	الغياب نفسه يحمل معلومة	يزيد عدد الميزات
التعبئة الأمامية (Forward fill) أو الاستيفاء (interpolation)	السلاسل الزمنية المرتبة	خاطئة عبر الفجوات الطويلة

نصيحة للاختبار

لإم (fit) كل أداة تعويض (imputer) على مجموعة التدريب فقط (داخل Pipeline)، ثم طَبِّقها على مجموعتي التحقق والاختبار. وإلا فإنك تُسَرِّب معلومات من بيانات الاختبار (leakage).

4.3 القيم الشاذة

قاعدة المدى الربيعي (IQR rule)

$$IQR = Q3 - Q1 \quad \cdot \quad \text{lower fence} = Q1 - 1.5 \cdot IQR \quad \cdot \quad \text{upper fence} = Q3 + 1.5 \cdot IQR$$

مثال: إذا كان $Q1 = 20$ و $Q3 = 40$ فإن $IQR = 20$ والحدان هما -10 و 70 ، لذا تُعَلَّم القيمة 75 كقيمة شاذة.

الدرجة المعيارية (Z-score)

$$z = (x - \mu) / \sigma \quad (\text{often flagged when } |z| > 3)$$

المتوسط والانحراف المعياري يتأثران هما أنفسهما بالقيم الشاذة، لذا قد تُعْطَلها الـ z-score في العينات الصغيرة أو الملتوية. والأكثر أماناً استخدام IQR أو z-score متينة (robust) مبنية على الوسيط و MAD.

قرّر أولاً: هل القيمة الشاذة خطأ، أم حدث نادر حقيقي؟

الحالة	المعالجة
خطأ إدخال بيانات أو خطأ حسّاس (عمر 250)	صحّحه، أو اجعله قيمة مفقودة ثم عوّضها
قيم حقيقية لكنها متطرفة وتشوّه النموذج	القص (Cap/winsorize)، أو التحويل اللوغاريتمي، أو استخدام نماذج أو دوال خسارة متينة
الأحداث النادرة هي الهدف (الاحتيال)	أبقها. فهي الإشارة نفسها.

- حساسة للقيم الشاذة: الانحدار الخطي (OLS)، و k-means، و kNN، و PCA، و MSE/RMSE، و StandardScaler.
- متينة (Robust): النماذج الشجرية (tree-based)؛ لأن التقسيمات تعتمد على الترتيب لا على المقدار، والوسيط، و MAE، و RobustScaler، و Huber loss.

4.4 تحويل المتغيرات الملتوية

- التحويل اللوغاريتمي (Log transform) $\log(x + 1)$ عند وجود أصفار) يضغط الذيل اليمني الطويلة مثل الدخل أو الأسعار.
- Box-Cox يتطلب قيمة موجبة تماماً. أما Yeo-Johnson فيتعامل أيضاً مع الصفر والقيم السالبة.
- النماذج الشجرية نادراً ما تحتاج هذه التحويلات. أما النماذج الخطية والمعتمدة على المسافة فغالباً ما تستفيد منها.

4.5 مشكلات جودة البيانات

المشكلة	مثال	الحل
فئات غير متسقة	"Riyadh", "riyadh ", "RUH"	وحد حالة الأحرف والمسافات؛ واربطها بقيمة قياسية (canonical)
وحدات مختلطة	أوزان بالكيلوغرام وبالغرام	حوّلها إلى وحدة واحدة
القيم البديلة (Sentinel values)	999- بمعنى «غير معروف»	استبدلها بقيمة مفقودة قبل حساب الإحصاءات
أنواع خاطئة	"1,250" مخزنة كنص	حلّلها وحوّل نوعها (cast)؛ وتحقق من النطاقات
صيغ تواريخ مختلطة	03/04/2025 تُقرأ على أنها مارس أو أبريل	حلّلها بصيغة صريحة؛ واستخدم ISO 8601
سجلات مكررة	الطلب نفسه أدخل مرتين	أزل التكرار بناءً على مفتاح العمل

5 هندسة الميزات والمعالجة المسبقة

5.1 ترميز المتغيرات الفئوية

المُرَّمز	آلية العمل	الأنسب لـ	انتبه إلى
الترميز الأحادي (One-hot)	عمود ثنائي لكل فئة	الفئات الاسمية ذات المستويات القليلة؛ النماذج الخطية	عدد فئات كبير (high cardinality) ← أعمدة متفرقة كثيرة
الترتيبي (Ordinal / label)	رمز صحيح لكل فئة	الفئات المرتبة فعلاً (low < medium < high)؛ النماذج الشجرية	يفرض ترتيباً زائفاً على البيانات الاسمية في النماذج الخطية والمعتمدة على المسافة
ترميز الهدف / الهدف (Target / mean encoding)	يستبدل الفئة بمتوسط قيمة الهدف	الميزات كثيرة الفئات (آلاف التجار)	تسرب (Leakage) ما لم يُنقذ خارج الطيئة-out (of-fold مع التنعيم smoothing)
التكرار / العدّ (Frequency / count)	يستبدل الفئة بتكرارها	عدد فئات كبير؛ النماذج الشجرية	قد تشارك فئات مختلفة العدد نفسه
التجزئة (Hashing)	يُجزئ الفئات في عدد ثابت من الأعمدة	عدد فئات كبير جداً وبيانات متدفقة (streaming)	تصادمات (Collisions)؛ غير قابل للتفسير

- **فخ المتغيرات الوهمية (Dummy-variable trap):** عند وجود حدّ ثابت (intercept) في نموذج خطي، احذف عموداً واحداً من أعمدة one-hot (drop_first) لتجنّب التعدد الخطي التام (perfect multicollinearity).
- **فئات غير مرئية وقت الاستدلال (inference):** استخدم handle_unknown="ignore" أو سلة «Other».
- **الفئات النادرة:** اجمع المستويات التي يقل تكرارها عن عتبة (threshold) معيّنة في فئة «Other».

5.2 تحجيم الميزات

أداة التحجيم (Scaler)	الصيغة	مق يُستخدم
StandardScaler	$(x - \text{mean}) / \text{std}$	الخيار الافتراضي للنماذج الخطية وSVM وPCA والشبكات العصبية
MinMaxScaler	$(x - \min) / (\max - \min) \rightarrow [0, 1]$	عند الحاجة إلى نطاق محدود (مثل مدخلات الشبكات العصبية أو بكسلات الصور)؛ دون قيم شاذة قوية
RobustScaler	$(x - \text{median}) / \text{IQR}$	الميزات التي تحتوي قيماً شاذة
MaxAbsScaler	$x / \max x $	البيانات المتفرقة (sparse)؛ يحافظ على الأصفار

- **تحتاج إلى تحجيم:** k-NN، وk-means، وSVM، وPCA، والانحدار الخطي أو اللوجستي المنظم (regularized)، والشبكات العصبية، وأي خوارزمية تستخدم الانحدار التدرجي (gradient descent) أو المسافات.
- **لا تحتاج إلى تحجيم:** أشجار القرار، والغابات العشوائية (random forests)، والتعزيز التدرجي (gradient boosting).

5.3 Pipelines و تسرب المعالجة المسبقة

القاعدة: قسم البيانات أولاً، ثم لاءم كل تحويل (أداة التعويض، والتحجيم، والترميز، واختيار الميزات، وإعادة المعاينة resampler) على بيانات التدريب فقط.

```
pipe = Pipeline([
    ("prep", ColumnTransformer([
        ("num", Pipeline([("impute", SimpleImputer(strategy="median")),
                          ("scale", StandardScaler())]), numeric_cols),
        ("cat", OneHotEncoder(handle_unknown="ignore"), categorical_cols)])),
    ("model", LogisticRegression(max_iter=1000))])
cross_val_score(pipe, X_train, y_train, cv=5) # preprocessing refit inside every fold
```

فخ شائع

تحجيم الميزات أو اختيارها على مجموعة البيانات كاملة قبل التحقق المتقاطع (cross-validation). عندها تكون طيات التحقق قد أثرت في المعالجة المسبقة، فتأتي الدرجات متفائلة أكثر من الواقع.

5.4 إنشاء ميزات مفيدة

- **التاريخ والوقت (Datetime):** الساعة، ويوم الأسبوع، والشهر، ومؤشرات عطلة نهاية الأسبوع أو العطلات الرسمية، والوقت منذ آخر حدث، والفترات الموسمية مثل رمضان.
- **الترميز الدوري (Cyclical encoding):** مثل الساعة بـ $\sin(2\pi \cdot h/24)$ و $\cos(2\pi \cdot h/24)$ ، لتكون الساعة 23:00 قريبة من 00:00.
- **التجميعات (Aggregations)** من جداول الأحداث: الأعداد، والمجاميع، والمتوسطات، والحدثة (recency) والتكرار (frequency) لكل عميل. استخدم فقط الأحداث السابقة لنقطة قطع التنبؤ (prediction cutoff).
- **النسب والتفاعلات (Ratios and interactions):** الذين إلى الدخل، وسعر المتر المربع، والإنفاق لكل زيارة.
- **التقسيم إلى فئات (Binning):** يحوّل الميزة الرقمية إلى نطاقات. قد يحسّن قابلية التفسير لكنه يفقد معلومات.
- **النصوص (Text):** حقيبة الكلمات (bag-of-words) أو TF-IDF مع n-grams؛ وحّد حالة الأحرف ونظّف علامات الترقيم؛ واحذف كلمات التوقف (stop words) عند الاقتضاء.

TF-IDF

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \log(N / \text{df}(t))$$

يحصل المصطلح على درجة عالية عندما يتكرر كثيراً في مستند ما لكنه نادر في مجموعة النصوص (corpus) كلها.

5.5 التعدد الخطي

المتنبئات شديدة الارتباط تجعل معاملات النموذج الخطي غير مستقرة وصعبة التفسير، حتى لو بقيت التنبؤات دقيقة. وهذا ما يُسمّى التعدد الخطي (Multicollinearity).

معامل تضخم التباين (Variance inflation factor – VIF)

$$\text{VIF}_j = 1 / (1 - R_j^2)$$

تأتي R_j^2 من انحدار الميزة j على بقية الميزات. تشير قيمة VIF أعلى من 5-10 إلى مشكلة، فاحذف الميزات أو ادمجها، أو استخدم انحدار .ridge.

5.6 اختيار الميزات

العائلة	أمثلة	ملاحظات
الترشيح (Filter)	عتبة التباين (Variance threshold)، والارتباط، ومربع كاي (chi-square)، والمعلومات المتبادلة (mutual information)	سريعة ومستقلة عن النموذج؛ تتجاهل التفاعلات بين الميزات
التغليف (Wrapper)	الحذف التكراري للميزات (RFE)، والاختيار الأمامي/الخلفي	تستخدم نموذجاً؛ مكلفة؛ وفيها خطر فرط التخصيص (overfitting)
الدمجة (Embedded)	معاملات L1 (Lasso)، وأهمية الميزات في الأشجار	يحدث الاختيار أثناء التدريب
أهمية التبديل (Permutation importance)	انخفاض درجة التحقق عند خلط قيم ميزة ما عشوائياً	مستقلة عن النموذج وموثوقة؛ الميزات المترابطة تنقسم الأهمية

لعنة الأبعاد (Curse of dimensionality): مع ازدياد عدد الميزات تصبح البيانات متفرقة وتفقد المسافات معناها. والطرق المعتمدة على المسافة هي الأكثر تضرراً. وتشمل العلاجات: اختيار الميزات، وتقليل الأبعاد (dimensionality reduction)، والتنظيم (regularization).

6.1 المفاضلة بين الانحياز والتباين (Bias–Variance Trade-off)

نقص الملاءمة (Underfitting) – انحياز مرتفع	فرط الملاءمة (Overfitting) – تباين مرتفع
خطأ التدريب مرتفع (Training error)	منخفض
خطأ التحقق مرتفع، وقريب من خطأ التدريب (Validation error)	أعلى بكثير من خطأ التدريب
منحنى التعلم (Learning curve) يستقر المنحنيان عند خطأ مرتفع؛ ولن تفيد زيادة البيانات	فجوة كبيرة تضيق كلما زادت البيانات؛ فزيادة البيانات تفيد
العلاج: نموذج أعقد، وميزات أكثر أو أفضل، وتنظيم (Regularization) أقل، وتدريب أطول	بيانات أكثر، وتنظيم، ونموذج أبسط، واختيار الميزات (Feature selection)، والإيقاف المبكر (Early stopping)، وال Dropout، والتقليم (Pruning)

قراءة منحنيات التعلم

إذا ظل خطأ التحقق ينخفض مع زيادة حجم بيانات التدريب وكانت الفجوة كبيرة، فاجمع بيانات أكثر. أما إذا كان المنحنيان مسطحين ومرتفعين، فغيّر النموذج أو الميزات بدلاً من ذلك.

6.2 الانحدار الخطي (Linear Regression)

يتنبأ هذا النموذج بقيمة رقمية على شكل مجموع موزون للميزات، ويُدرَّب بتقليل مجموع مربعات الخطأ (OLS).

- **الافتراضات (Assumptions):** علاقة خطية، واستقلال الأخطاء، وثبات تباين الخطأ (Homoscedasticity)، وبواقي (Residuals) قريبة من التوزيع الطبيعي (وهذا لازم للاستدلال الإحصائي). وتجنّب كذلك التعدد الخطي (Multicollinearity) القوي.
- **التشخيص (Diagnostics):** ارسم البواقي مقابل القيم المتوقعة (Residuals vs fitted). الشكل القمعي يعني عدم ثبات التباين (Heteroscedasticity)، فجرّب أخذ لوغاريتم المتغير الهدف. والشكل المنحني يعني وجود علاقة غير خطية لم تُمثّل، فأضف حدوداً جديدة.
- **المعامل (Coefficient):** التغير المتوقع في y عند زيادة x بوحدة واحدة، مع تثبيت بقية الميزات.

6.3 الانحدار اللوجستي (Logistic Regression)

النموذج

$$p = 1 / (1 + e^{-z}), \quad z = \beta_0 + \beta_1 x_1 + \dots \quad \cdot \quad \log\text{-odds} = z$$

المعامل β يضرب الأرجحية (Odds) في e^β مع كل زيادة بوحدة واحدة في الميزة. وعندما يكون $z = 0$ فإن $p = 0.5$.

- نموذج مرجعي (Baseline) قوي للتصنيف: سريع، واحتمالاته معايرة جيداً (Well-calibrated)، وقابل للتفسير؛ ولذلك يناسب القرارات الخاضعة للتنظيم كالاتّمان.
- حدّ القرار (Decision boundary) فيه خطي، والأنماط غير الخطية تتطلب هندسة ميزات.
- يُدرَّب بدالة الخسارة اللوغاريتمية (Log loss) أو الإنتروبيا المتقاطعة (Cross-entropy).

6.4 التنظيم (Regularization)

النوع	العقوبة (Penalty)	الأثر	مق يُستخدم
L1 (Lasso)	$\lambda \cdot \sum \beta $	يدفع بعض المعاملات إلى الصفر تماماً ← اختيار للميزات	ميزات كثيرة، والمفيد منها فعلاً قليل
L2 (Ridge)	$\lambda \cdot \sum \beta^2$	يقلص جميع المعاملات بسلاسة؛ ويتعامل مع الميزات المترابطة	التعدد الخطي؛ وتأثيرات صغيرة كثيرة
ElasticNet	مزيج من L1 و L2	نموذج متناثر (Sparse) ومستقر مع مجموعات الميزات المترابطة	ميزات مترابطة كثيرة

- كلما كبرت λ (أو α) زادت قوة التنظيم، فينتج نموذج أبسط بانحياز أعلى وتباين أقل.
- في LogisticRegression و SVM ضمن scikit-learn يكون $C = 1/\lambda$ ، أي أن قيمة C الأصغر تعني تنظيماً أقوى.
- وخذ مقاييس الميزات (Scaling) قبل التنظيم حتى تعاملها العقوبة بالتساوي.

6.5 أشجار القرار (Decision Trees)

- تقسم الشجرة البيانات بقواعد «إذا/فإن» تُختار لتعظيم النقاء (Purity). وتستخدم شوائب جيني (Gini impurity) أو الإنتروبيا (Entropy) في التصنيف، وتقليل التباين (MSE) في الانحدار.
- **نقاط القوة:** قابلة للتفسير، وتتعامل مع العلاقات غير الخطية والتفاعلات، ولا تحتاج إلى توحيد المقاييس، وممتينة أمام القيم الشاذة (Outliers) في الميزات.
- **نقاط الضعف:** الأشجار العميقة تقع في فرط الملاءمة، وقد ينتج عن تغيير بسيط في البيانات شجرة مختلفة تماماً (عدم الاستقرار).
- **ضبط التعقيد** عبر max_depth و min_samples_leaf و min_samples_split، والتقليم بتكلفة التعقيد (ccp_alpha).

شوائب جيني (Gini impurity)

$$Gini = 1 - \sum p_k^2$$

عقدة فيها 60% من الفئة A و 40% من الفئة B قيمة جيني لها $Gini = 1 - (0.36 + 0.16) = 0.48$. أما العقدة النقية فقيمها $Gini = 0$.

6.6 نماذج كلاسيكية أخرى

النموذج	الفكرة الأساسية	نقاط القوة	نقاط الضعف
أقرب الجيران (k-nearest neighbours)	يتنبأ اعتماداً على أقرب k نقاط من بيانات التدريب	بسيط، بلا مرحلة تدريب، وغير خطي	بطيء في التنبؤ على البيانات الكبيرة؛ يحتاج إلى توحيد المقاييس؛ ويتأثر سلباً بالأبعاد العالية. قيمة k الصغيرة تسبب فرط الملاءمة، والكبيرة تسبب نقصها.
آلة المتجهات الداعمة (Support Vector Machine)	حدّ فاصل بأقصى هامش (Maximum margin)؛ والنوى (Kernels) تجعله غير خطي	فعّال في الأبعاد العالية ومع البيانات متوسطة الحجم	لا يتوسع جيداً مع البيانات الضخمة جداً؛ ويحتاج إلى توحيد المقاييس وضبط C و gamma
بايز الساذج (Naive Bayes)	مبرهنة بايز مع افتراض استقلال الميزات	سريع جداً؛ ونموذج مرجعي قوي للنصوص	افتراض الاستقلال يجعل الاحتمالات ضعيفة المعايير

معاملات SVM: قيمة C الكبيرة تعني هامشاً ضيقاً وأخطاء تدريب أقل (مع خطر فرط الملاءمة). وقيمة gamma الكبيرة (في نواة RBF) تجعل تأثير كل نقطة محلياً، فينتج حدّ متعرج (مع خطر فرط الملاءمة).

6.7 اختيار النموذج في ظل القيود

القيد	خيارات مناسبة
يجب تفسير كل قرار للجهات التنظيمية أو العملاء	الانحدار اللوجستي أو الخطي، والأشجار الضحلة، وبطاقات التقييم (Scorecards)
بيانات جدولية (Tabular)، وأعلى دقة	التعزيز المتدرج (Gradient boosting) مثل XGBoost و LightGBM و CatBoost، والغابة العشوائية (Random forest)
زمن استجابة (Latency) منخفض جداً أو جهاز طرفي (Edge device)	النماذج الخطية، والأشجار الصغيرة، والنماذج المضغوطة
مجموعة بيانات صغيرة	نماذج بسيطة مع تنظيم؛ وتحقق متقاطع (Cross-validation) صارم
صور وصوت ونصوص حرة على نطاق واسع	التعلم العميق (Deep learning)، وغالباً بنقل التعلم (Transfer learning) من نماذج مُدرّبة مسبقاً

6.8 ضبط المعاملات الفائقة (Hyperparameter Tuning)

- **البحث الشبكي (Grid search):** يجرب كل التركيبات. التكلفة = (حاصل ضرب عدد القيم لكل معامل) × (عدد الطيات). وتتضمن بسرعة: $4 \times 3 \times 5$ قيم مع تحقق متقاطع بـ 5 طيات (300 = 5-fold CV) عملية تدريب.
- **البحث العشوائي (Random search):** يأخذ عينات من التركيبات، وغالباً يصل إلى إعدادات جيدة أسرع عندما يكون عدد المعاملات المؤثرة قليلاً.
- **التحسين البايزي (Bayesian optimization)** (مثل Optuna): يستفيد من النتائج السابقة لاختيار إعدادات واعدة، ما يجعله كفؤاً مع النماذج المكلفة.
- **التنصيف المتتابع (Successive halving) / Hyperband:** يمنح مرشحين كثيرين ميزانية صغيرة، ثم يُبقي الأفضل فقط.
- **اضبط المعاملات على بيانات التحقق أو بالتحقق المتقاطع، ولا تضبطها على مجموعة الاختبار أبداً.**

استراتيجيات التصنيف متعدد الفئات (Multi-class)

أسلوب واحد-مقابل-البقية (One-vs-rest) يدرب K نموذجاً ثنائياً. وأسلوب واحد-مقابل-واحد (One-vs-one) يدرب $K(K-1)/2$ نموذجاً، أي 45 نموذجاً لعشر فئات. أما Softmax (المتعدد الحدود Multinomial) فينمذج جميع الفئات K معاً.

7 التجميع (Ensembles) والبيانات غير المتوازنة

7.1 ال Bagging وال Boosting وال Stacking

التدريب	ال Bagging (مثل الغابة العشوائية)	التعزيز Boosting (مثل XGBoost و LightGBM)	التكديس Stacking
يقلل أساساً	التباين	الانحياز (والتباين)	يختلف
خطر فرط الملاءمة	منخفض؛ وزيادة عدد الأشجار لا تسبب فرط ملاءمة	أعلى؛ والجولات الكثيرة تسبب فرط الملاءمة دون إيقاف مبكر	يحتاج إلى تنبؤات خارج الطية (Out-of-fold)
جهد الضبط	منخفض	أعلى	مرتفع

7.2 الغابة العشوائية (Random Forest)

- ترى كل شجرة عينة Bootstrap، ومجموعة جزئية عشوائية من الميزات عند كل تقسيم (`max_features`). وهذا يقلل الارتباط بين الأشجار، فيؤدي أخذ متوسطها إلى خفض التباين.
- درجة خارج الحقيبة (`Out-of-bag, OOB score`): تُقيّم كل شجرة على نحو 37% من الصفوف التي لم ترها، فنحصل على تقدير تحقق مجاني.
- أهمية الميزات المبنية على الشواثب (`Impurity-based feature importance`) منحازة نحو الميزات عالية الكاردينالية (`High-cardinality`) والمتصلة. فضل أهمية التبديل (`Permutation importance`) أو SHAP.

7.3 التعزيز المتدرج (Gradient Boosting)

- معدل التعلم (`Learning rate`) مقابل عدد الأشجار: معدل التعلم الأصغر يحتاج إلى أشجار أكثر، لكنه غالباً يعمّم بشكل أفضل.
- الإيقاف المبكر (`Early stopping`): توقّف عن إضافة الأشجار عندما تتوقف درجة التحقق عن التحسن.
- ضوابط فرط الملاءمة: `max_depth` و `min_child_weight` و `subsample` (للفصوف) و `colsample_bytree` (للميزات)، والتنظيم `L1/L2`.
- يتعامل XGBoost و LightGBM مع القيم المفقودة تلقائياً، ويتعامل CatBoost مع الميزات الفئوية تلقائياً. و LightGBM سريع جداً على البيانات الكبيرة.
- علامة فرط الملاءمة: تستمر خسارة التدريب في الانخفاض بينما تبدأ خسارة التحقق في الارتفاع.

7.4 الفئات غير المتوازنة (Imbalanced Classes)

التقنية	الطريقة	ملاحظات
استخدام المقياس الصحيح	الدقة (Precision) والاستدعاء (Recall) و F1 و PR-AUC بدلاً من الصحة (Accuracy)	الخطوة الأولى دائماً
أوزان الفئات (Class weights)	معاينة أخطاء فئة الأقلية أكثر (<code>class_weight="balanced"</code>) (<code>scale_pos_weight</code>)	بلا تغيير في البيانات؛ بسيطة وفعالة
تحريك ال Threshold	اختيار حد القطع للاحتمال بناءً على تكاليف العمل	غالباً أكبر مكسب

التقنية	الطريقة	ملاحظات
زيادة العينات العشوائية (Random oversampling)	تكرار صفوف فئة الأقلية	خطر فرط الملاءمة على الصفوف المكررة
SMOTE	توليد نقاط اصطناعية لفئة الأقلية بين الجيران	للميزات الرقمية؛ وقد يولّد ضوضاء قرب مناطق تداخل الفئات
تقليل العينات (Undersampling)	حذف صفوف من فئة الأغلبية	سريع؛ لكنه يفقد معلومات
كشف الشذوذ (Anomaly detection)	نمذجة الحالة «الطبيعية» فقط	عندما تكون الحالات الموجبة نادرة جداً أو غير موسومة

وزن الفئة المتوازن (Balanced class weight)

$$w_c = n_samples / (n_classes \times n_c)$$

مع 10,000 صف و500 حالة موجبة، يكون وزن الفئة الموجبة $10 = 10,000 / (2 \times 500)$.

فخ شائع

إعادة أخذ العينات (SMOTE أو Oversampling) قبل تقسيم التدريب/الاختبار، أو خارج طيّات التحقق المتقاطع. عندها تتسرب نسخ اصطناعية من نقاط الاختبار إلى التدريب. أعد أخذ العينات على طيّة التدريب فقط، مثلاً باستخدام Pipeline من imblearn.

بعد إعادة أخذ العينات أو إعادة الوزن، لا تعكس الاحتمالات المتوقعة المعدلات الحقيقية. أعد معايرتها (Recalibrate) إن كنت تحتاج إلى احتمالات حقيقية.

8.1 خوارزميات العنقدة (Clustering)

الخوارزمية	ما تجده	تحتاج k؟	نقاط القوة	نقاط الضعف
k-means	عناقيد كروية متقاربة الحجم	نعم	سريعة؛ وتتوسع جيداً	تحتاج إلى توحيد المقاييس؛ حساسة للقيم الشاذة وللتهيئة الأولية؛ ضعيفة مع الأشكال غير المنتظمة
الهرمية التجميعية (Hierarchical agglomerative)	شجرة من العناقيد المتداخلة (Dendrogram)	لا (تقطع الشجرة)	مرئية؛ وأي قيمة k من تشغيل واحد	بطيئة على البيانات الكبيرة
DBSCAN	مناطق كثيفة بأي شكل؛ وتحدد الضوضاء	لا (eps)، (min_samples)	أشكال عشوائية؛ وتكتشف القيم الشاذة	تتعثّر مع تفاوت الكثافات؛ حساسة لـ eps
المزيج الغاوسي (Gaussian mixture)	عناقيد إهليلجية بعضوية مرنة (Soft membership)	نعم	تعيينات احتمالية	تفترض أشكالاً غاوسية؛ وأبطأ

- **اختيار k: طريقة الكوع (Elbow method)** (النقطة التي يتباطأ عندها انخفاض مجموع المربعات داخل العناقيد) و**درجة الظل (Silhouette score)** (من -1 إلى 1؛ والأعلى يعني عناقيد أوضح انفصلاً).
- وخذ مقاييس الميزات دائماً مع k-means، واستخدم تهيئة k-means++ مع عدة إعادة تشغيل (n_init).
- تحقق من العناقيد مع جهة العمل: هل الشرائح متميزة ومستقرة وقابلة للتنفيذ؟

8.2 تقليل الأبعاد (Dimensionality Reduction)

- **تحليل المكونات الرئيسية (PCA)** يجد اتجاهات متعامدة ذات أقصى تباين. وخذ المقاييس (Standardize) أولاً، وإلا هيمنت الميزات ذات المقاييس الكبيرة. احتفظ بعدد كافٍ من المكونات لتفسير نحو 90-95% من التباين مثلاً.
- يفيد PCA في التصور، وتقليل الضوضاء، ومعالجة التعدد الخطي، وتسريع الأداء. والثمن هو قابلية التفسير، لأن المكونات تمزج الميزات الأصلية.
- **PCA مقابل اختيار الميزات:** الاختيار يُبقي الميزات الأصلية القابلة للتفسير، بينما يولّد PCA ميزات جديدة مركبة.
- **t-SNE وUMAP:** تضمينات (Embeddings) غير خطية ثنائية أو ثلاثية الأبعاد للتصور فقط. المسافات بين العناقيد المتباعدة ليست ذات معنى، ولا تصلح كميزات للنماذج في بيئة الإنتاج.

8.3 كشف الشذوذ (Anomaly Detection)

- **غابة العزل (Isolation Forest):** تُعزل الحالات الشاذة بعدد أقل من التقسيمات العشوائية. وهي سريعة على البيانات عالية الأبعاد. اضبط contamination على معدل الشذوذ المتوقع.
- **القواعد الإحصائية:** درجة z (z-score) أو المدى الربيعي (IQR) على ميزات منفردة. بسيطة لكنها أحادية المتغير.
- **المبنية على الكثافة أو المسافة:** Local Outlier Factor، ونقاط الضوضاء في DBSCAN.
- **نماذج الفئة الواحدة / (One-class) المشفرات التلقائية (Autoencoders):** تتعلم الحالة «الطبيعية» وتُعلّم على أخطاء إعادة البناء (Reconstruction errors) الكبيرة.

9 السلاسل الزمنية والنصوص وأنظمة التوصية والتعلم العميق

9.1 السلاسل الزمنية (Time Series)

- المكونات: الاتجاه العام (Trend)، والموسمية (Seasonality) اليومية والأسبوعية والسنوية ومواسم رمضان والحج، والدورات (Cycles)، والضوضاء (Noise).
- لا تقسم البيانات عشوائياً أبداً. درّب على الماضي وتحقق على المستقبل (Time-series split / Forward chaining).
- ميزات الإزاحة (Lag) والنوافذ المتحركة (Rolling): قيمة الأسبوع الماضي، والمتوسط المتحرك لـ 7 أيام. احسبها فقط من البيانات السابقة لوقت التنبؤ.
- النماذج المرجعية (Baselines): الساذج (آخر قيمة)، والساذج الموسمي (اليوم نفسه من الأسبوع الماضي). النموذج الذي لا يتفوق عليهما غير مفيد.
- الاستقرارية (Stationarity): ثبات المتوسط والتباين عبر الزمن. والتفريق (Differencing) يزيل الاتجاه العام، كما تتطلب نماذج عائلة ARIMA.

9.2 النصوص (NLP)

الأسلوب	مقي
+ TF-IDF نموذج خطي	نموذج مرجعي سريع وقوي؛ بيانات صغيرة؛ مهام تعتمد على الكلمات المفتاحية مثل كشف الرسائل المزعجة (Spam) أو توجيه التذاكر
تضمينات الكلمات أو الجمل (Embeddings)	عندما يهم المعنى والتشابه (البحث، العقدة)
محول (Transformer) مُدرّب مسبقاً ومضبوط (Fine-tuned)	أعلى دقة مع اللغة الدقيقة الفروق؛ يحتاج إلى قدرة حوسبة أكبر؛ والنماذج المخصصة للعربية تساعد

9.3 أنظمة التوصية (Recommender Systems)

- الترشيح التعاوني (Collaborative filtering): «المستخدمون الذين يشبهونك أعجبهم أيضاً». يحتاج إلى سجل تفاعلات، لذا يعاني من البداية الباردة (Cold start) مع المستخدمين والعناصر الجدد.
- المبني على المحتوى (Content-based): يوصي بعناصر مشابهة لما أعجب المستخدم، اعتماداً على خصائص العناصر. ويعمل مع العناصر الجديدة.
- الهجين (Hybrid): يجمع الأسلوبين. وللمستخدمين الجدد، البديل الشائع هو العناصر الأكثر شعبية أو الرائجة.

9.4 أساسيات الشبكات العصبية (Neural Networks)

- يؤتي التعلم العميق ثماره مع البيانات الكبيرة والمدخلات غير المهيكلية (الصور، الصوت، النصوص). أما على البيانات الجدولية، فالتعزيز المتدرج عادةً مماثل أو أفضل، وأقل تكلفة.
- نقل التعلم (Transfer learning): ابدأ من نموذج مُدرّب مسبقاً واضبطه (Fine-tune) على بياناتك. وهو ضروري عندما تكون البيانات الموسومة محدودة.
- معدل التعلم (Learning rate): إن كان مرتفعاً جداً تتباعد الخسارة أو تتذبذب؛ وإن كان منخفضاً جداً يصبح التدريب بطيئاً جداً.
- ضوابط فرط الملاءمة: ال Dropout، وتضاؤل الأوزان (Weight decay, L2)، وزيادة البيانات (Data augmentation)، والإيقاف المبكر.

- **حجم الدفعة (Batch size):** الدفعات الأكبر أسرع في كل حقبة (Epoch) لكنها تحتاج إلى ذاكرة أكبر. عند أخطاء نفاد الذاكرة (Out-of-memory)، قلّل حجم الدفعة أو استخدم تجميع التدرجات (Gradient accumulation).

10.1 مصفوفة الالتباس (Confusion Matrix)

متوقع إيجابي (Predicted positive)	متوقع سلبي (Predicted negative)
إيجابي فعلي (Actual positive)	إيجابي صحيح (true positive) TP
سلبي فعلي (Actual negative)	إيجابي كاذب (false positive) – إنذار كاذب FP
	سلبي صحيح (true negative) TN
	سلبي كاذب (false negative) – حالة فائتة FN

المقياس	الصيغة	السؤال الذي يجب عنه
الدقة الكلية (Accuracy)	$(TP + TN) / \text{total}$	كم مرة يصيب النموذج إجمالاً؟
الدقة (Precision)	$TP / (TP + FP)$	حين يقول «إيجابي»، كم مرة يكون محققاً؟
الاستدعاء (Recall) – الحساسية TPR, (sensitivity)	$TP / (TP + FN)$	من كل الحالات الإيجابية الحقيقية، كم حالة التقط؟
النوعية (Specificity), TNR	$TN / (TN + FP)$	من كل الحالات السلبية الحقيقية، كم حالة استبعد بشكل صحيح؟
معدل الإيجابيات الكاذبة (False positive rate)	$FP / (FP + TN) = 1 - \text{specificity}$	كم حالة سلبية وُسمت خطأ بأنها إيجابية؟
مقياس F1 (F1-score)	$2 \cdot P \cdot R / (P + R)$	توازن بين الدقة والاستدعاء (المتوسط التوافقي harmonic mean)
مقياس F-beta	$(1 + \beta^2) \cdot P \cdot R / (\beta^2 \cdot P + R)$	القيمة $\beta > 1$ تعطي الاستدعاء وزناً أكبر (F2)؛ والقيمة $\beta < 1$ تعطي الدقة وزناً أكبر (F0.5)

مثال محلول

TP = 80, FN = 20, FP = 40, TN = 860 (المجموع 1,000).

Precision = $80/120 = 66.7\%$ · Recall = $80/100 = 80\%$ · Specificity = $860/900 = 95.6\%$
 · Accuracy = $940/1000 = 94\%$ · F1 = 72.7%

10.2 الدقة أم الاستدعاء؟ القرار يحدده ثمن الخطأ

حالة الاستخدام	الخطأ الأعلى كلفة	الأولوية لـ
الكشف المبكر عن السرطان أو الأمراض	تفويت مريض مصاب (FN)	الاستدعاء (Recall)
كشف الاحتيال (مع وجود قدرة على المراجعة)	تفويت عملية احتيال (FN)	الاستدعاء، مع دقة مقبولة
مرشّح البريد المزعج (Spam filter)	ضياح رسالة حقيقية (FP)	الدقة (Precision)
حملة احتفاظ بالعملاء بميزانية محدودة	هدر الاتصالات على عملاء لن يغادروا (FP)	الدقة ضمن أعلى k حالة يُتواصل معها
الحظر التلقائي للحسابات	حظر عميل سليم (FP)	الدقة (Precision)
الصيانة التنبؤية للمعدات الحرجة	عطل لم يُكتشف (FN)	الاستدعاء (Recall)

مفارقة الدقة الكلية (Accuracy paradox)

إذا كانت نسبة الاحتيال 1%، فالنموذج الذي يتنبأ بـ«ليس احتيالياً» لكل الحالات يحقق دقة كلية 99% واستدعاءً 0.0%. لا تحكم على مسألة غير متوازنة بالدقة الكلية أبداً.

10.3 العتبات، ومنحنيا ROC وPR

- معظم المصنّفات تُخرج احتمالاً. والعتبة الافتراضية (threshold) عند 0.5 اختيار اعتباطي. **خفض العتبة** يرفع الاستدعاء (Recall) ويخفض الدقة (Precision)؛ و**رفعها** يفعل العكس.
- منحنى ROC**: معدل TPR مقابل FPR عبر كل العتبات. وقيمة **ROC-AUC** هي احتمال أن تُرتّب حالة إيجابية عشوائية فوق حالة سلبية عشوائية (0.5 = عشوائي، 1.0 = مثالي).
- منحنى PR**: الدقة مقابل الاستدعاء. ومقياس **PR-AUC / متوسط الدقة (average precision)** أكثر إفادة من ROC-AUC حين تكون الحالات الإيجابية نادرة، لأن ROC-AUC قد يبدو ممتازاً بينما الدقة ضعيفة.
- يقيس AUC جودة الترتيب (ranking)، ولا يأخذ في الحسبان العتبة ولا المعايير.

اختيار العتبة بحسب الكلفة

$$\text{Total cost} = \text{FP} \times \text{cost}_{\text{FP}} + \text{FN} \times \text{cost}_{\text{FN}}$$

احسبها على بيانات التحقق عند كل عتبة مرشّحة، واختر العتبة ذات الكلفة الأدنى. وحين تكون الاحتمالات معايرة، تكون عتبة التعادل $\text{cost}_{\text{FP}} / (\text{cost}_{\text{FP}} + \text{cost}_{\text{FN}})$.

10.4 المعايرة (Calibration)

- يكون النموذج **معايراً (calibrated)** إذا كان نحو 70% من الحالات التي تنبأ لها باحتمال 70% إيجابية فعلاً. ويمكنك التحقق من ذلك بمخطط الموثوقية (reliability diagram).
- تهمّ المعايرة حين تقود الاحتمالات القرارات: التسعير بحسب الخسارة المتوقعة (expected loss)، ودرجات المخاطر، والعتبات المبنية على الكلفة.
- الطرق**: Platt scaling (دالة sigmoid) للبيانات الصغيرة، والانحدار المتساوي التوتر (isotonic regression) للبيانات الأكبر. درّبها على بيانات محجوزة (held-out).
- المقاييس**: درجة Brier (Brier score) $\text{mean}((p - y)^2)$ ، والأقل أفضل؛ والخسارة اللوغاريتمية (log loss)، التي تعاقب بشدة التنبؤات الخاطئة الواثقة.
- كثيراً ما تكون أشجار التعزيز (Boosted trees) وNaive Bayes وSVM، والنماذج المدوّنة على بيانات أُعيد أخذ عيناتها (resampled)، ضعيفة المعايرة.

10.5 مقاييس التصنيف متعدد الفئات (Multi-class)

طريقة حساب المتوسط (Averaging)	الطريقة	متى تُستخدم
Macro	احسب المقياس لكل فئة، ثم خذ المتوسط البسيط	حين تكون لكل فئة الأهمية نفسها، بما فيها الفئات النادرة
Weighted	متوسط الفئات موزوناً بعدد حالات كل فئة (support)	لتعكس التوزيع الكلي للفئات

طريقة حساب المتوسط (Averaging)	الطريقة	متى تُستخدم
Micro	اجمع كل TP و FP و FN عبر الفئات معًا	للأداء الإجمالي؛ ويساوي الدقة الكلية (Accuracy) في مسائل التسمية الواحدة (single-label)

10.6 مقاييس الترتيب والحملات

- **Precision@k**: نسبة الإيجابيات الحقيقية بين أعلى k حالة من حيث الدرجة. استخدمه حين لا تستطيع التصرف إلا في k حالة.
- **الرفع (Lift)** = معدل الاستجابة في المجموعة المستهدفة ÷ معدل الاستجابة الإجمالي. ورفعه قدره 3 في العُشير الأعلى (top decile) يعني أداءً أفضل بثلاث مرات من الاستهداف العشوائي.
- **المكاسب التراكمية (Cumulative gains)**: نسبة كل الحالات الإيجابية التي تُلتقط عند التواصل مع أعلى x% من الحالات.

11.1 مقاييس الانحدار (Regression metrics)

المقياس	الصيغة	الخصائص
MAE	$\text{mean } y - \hat{y} $	بوحدة المتغير الهدف؛ كل خطأ يُحتسب بنسبته؛ أقل حساسية للقيم الشاذة (outliers)
MSE	$\text{mean } (y - \hat{y})^2$	بوحدة مرتعة؛ يعاقب الأخطاء الكبيرة بشدة
RMSE	$\sqrt{\text{MSE}}$	بوحدة المتغير الهدف؛ ولا يزال يعاقب الأخطاء الكبيرة أكثر من MAE
MAPE	$\text{mean } y - \hat{y} / y $	نسبة مئوية سهلة الشرح؛ غير معرّف عند $y = 0$ وينفجر قرب الصفر؛ ويعاقب التقديرات الزائدة (over-forecasts) أكثر
R^2	$1 - SS_{\text{res}} / SS_{\text{tot}}$	نسبة التباين المفسّر؛ وقد يكون سالبًا حين يكون النموذج أسوأ من التنبؤ بالمتوسط
R^2 المعدّل (Adjusted R^2)	$1 - (1 - R^2)(n - 1)/(n - p - 1)$	يعاقب إضافة متغيرات تنبؤية عديمة الفائدة
الخطأ المطلق الوسيط (Median absolute error)	$\text{median } y - \hat{y} $	متين جدًا أمام السجلات التالفة

اختيار مقياس الانحدار

إذا كانت الأخطاء الكبيرة مكلفة بشكل غير متناسب، فاستخدم RMSE. وإذا كانت كل وحدة خطأ تكلف القدر نفسه، فاستخدم MAE. وإذا احتاج أصحاب المصلحة إلى نسب مئوية وكانت القيم الهدف لا تقترب من الصفر، فاستخدم MAPE (أو WAPE).

11.2 مجموعات التدريب والتحقق والاختبار

- **مجموعة التدريب (Training set):** لتقدير معاملات (parameters) النموذج.
- **مجموعة التحقق (Validation set) أو التحقق المتقاطع (cross-validation):** لاختيار النماذج والخصائص والمعاملات الفائقة (hyperparameters) والعتبات.
- **مجموعة الاختبار (Test set):** تقدير نهائي واحد غير متحيز. استخدمها مرة واحدة فقط. فالرجوع إليها مرارًا والتعديل بناءً عليها يحوّلها إلى مجموعة تحقق ويجعل التقدير متفائلًا.

11.3 استراتيجيات التحقق المتقاطع (Cross-validation)

الاستراتيجية	مق يُستخدم
التقسيم بالحجز (Hold-out split)	بيانات كبيرة جدًا؛ تجارب سريعة
K-fold (k = 5 or 10)	الحالة العامة؛ تقدير أكثر استقرارًا من تقسيم واحد
K-fold الطبقي (Stratified K-fold)	التصنيف، وخاصة غير المتوازن؛ يحافظ على نسبة الفئات في كل طية (fold)
K-fold بالمجموعات (Group K-fold)	عدة صفوف لكل عميل أو مريض أو جهاز؛ يجب ألا تظهر المجموعة نفسها في التدريب والتحقق معًا

الاستراتيجية	متى تُستخدم
تقسيم السلاسل الزمنية (Time-series split / forward chaining)	البيانات الزمنية؛ درّب دائمًا على الماضي وتحقّق على المستقبل
استبعاد حالة واحدة (Leave-one-out)	مجموعات بيانات صغيرة جدًا؛ تباين مرتفع وكلفة عالية
التحقق المتقاطع المتداخل (Nested CV)	ضبط المعاملات الفائقة والإبلاغ عن تقدير أداء غير متحيز في آن واحد

11.4 تسرب البيانات (Data leakage)

يحدث التسرب حين تصل إلى التدريب معلومات لن تكون متاحة وقت التنبؤ. فتبدو النتائج ممتازة خارج بيئة الإنتاج (offline)، ثم تنهار في الإنتاج.

النوع	مثال	الوقاية
تسرب الهدف (Target leakage)	استخدام «refund_issued» للتنبؤ بالاحتيايل؛ واستخدام «discharge_date» للتنبؤ بمدة الإقامة في المستشفى	اسأل عن كل خاصية: هل هي معروفة لحظة التنبؤ؟
تسرب المعالجة المسبقة (Preprocessing leakage)	التحجيم (scaling) أو تعويض القيم المفقودة (imputation) أو اختيار الخصائص على كل البيانات قبل التقسيم	درّب المحوّلات (transformers) داخل Pipeline على طيّات التدريب فقط
التسرب الزمني (Temporal leakage)	تقسيم عشوائي لبيانات مرتبة زمنيًا؛ خصائص تستخدم قيمًا من المستقبل	تقسيم زمني؛ وحساب الخصائص كما كانت في تلك اللحظة (point-in-time)
تسرب المجموعات (Group leakage)	صور أشعة المريض نفسه في التدريب والاختبار معًا	GroupKFold / التقسيم بحسب الكيان
تسرب التكرار (Duplicate leakage)	صفوف شبه متطابقة على جانبي التقسيم	أزل التكرارات قبل التقسيم
تسرب إعادة أخذ العينات (Resampling leakage)	تطبيق SMOTE قبل التقسيم	أعد أخذ العينات في طيّة التدريب فقط

«أجمل من أن يكون حقيقيًا»

الدرجة المرتفعة على نحو غير متوقع (مثل AUC بقيمة 0.99 في مسألة صعبة)، أو خاصية واحدة ذات أهمية طاعية، علامة تحذير من التسرب. تحقّق قبل أن تحتفل.

11.5 المقارنة العادلة بين النماذج

- استخدم الطيّات والبيانات نفسها لكل نموذج مرشّح، وقارن دائمًا بنموذج أساس بسيط (baseline).
- انظر إلى التذبذب بين الطيّات. ففرق 0.2% يقع ضمن ضجيج التفاوت بين الطيّات ليس تحسنًا حقيقيًا.
- أجرِ تحليل الأخطاء (error analysis) بتقسيم الأداء حسب الشرائح (المنطقة، الجهاز، نوع العميل). فالمتوسط الجيد قد يُخفي مجموعة يفشل فيها النموذج.
- تأكد أن بيانات الاختبار تمثّل بيئة الإنتاج (الفترة الزمنية نفسها، والمجتمع نفسه، ومصادر البيانات نفسها).
- المقياس خارج الإنتاج (offline) مجرد مؤشر بديل (proxy). أكّد القيمة التجارية في بيئة التشغيل الحية (اختبار A/B، أو النشر الظلي shadow deployment).

12.1 أنماط تقديم النموذج (Serving patterns)

الاستدلال الفوري (Online / real-time inference)	الاستدلال الدفعي (Batch inference)	الطريقة
حساب درجة كل طلب لحظيًا عبر API	حساب درجات عدد كبير من السجلات وفق جدول زمني وتخزين النتائج	
أجزاء من الثانية (Milliseconds)	من دقائق إلى ساعات	زمن الاستجابة (Latency)
كشف احتيالات البطاقات عند الدفع، وترتيب نتائج البحث	درجات التسرّب الليلية للعملاء (churn)، وتوقعات الطلب الأسبوعية	أمثلة
أعلى: زمن الاستجابة، والتوسع (scaling)، والإتاحة (availability)	أقل	التعقيد

12.2 التحزيم وقابلية إعادة الإنتاج

- **التسلسل (Serialization):** صيغتا pickle/joblib خاصتان ببايثون، وقد تتعطلان بين إصدارات المكتبات، ويجب ألا تُحمّل أبدًا من مصادر غير موثوقة لأن التحميل قد ينقذ شيفرة. أما ONNX فتوفر صيغة محمولة مستقلة عن إطار العمل.
- **REST API:** غُلف النموذج باستخدام FastAPI أو Flask، وتحقق من مخطط المدخلات (input schema)، وأعد التنبؤات مع وسم للإصدار.
- **Docker:** الـ image هي البيئة المحرّمة (الشيفرة + الاعتماديات)؛ والـ container نسخة قيد التشغيل منها. وهذا يضمن السلوك نفسه على كل جهاز.
- **قابلية إعادة الإنتاج (Reproducibility):** تُثبت إصدارات الاعتماديات، وتُثبت البذور العشوائية (random seeds)، وأدر إصدارات البيانات والنماذج، وتتبع التجارب (المعاملات، والمقاييس، والمخرجات artifacts) بأداة مثل MLflow.
- **سجل النماذج (Model registry):** المستودع المركزي لإصدارات النماذج، مع مراحل (archived, production, staging) وتتبع لأصل النموذج (lineage) يعود إلى البيانات والشيفرة.
- **CI/CD لتعلّم الآلة:** اختبارات آلية للشيفرة، والتحقق من البيانات (المخطط، والنطاقات، والقيم الفارغة)، وبوابات جودة (quality gates) للنموذج قبل ترقية.

12.3 انحراف التدريب عن التقديم (Training-serving skew) ومخازن الخصائص

انحراف التدريب عن التقديم (Training-serving skew) يحدث حين تُحسب الخصائص بطريقة في التدريب (مثل مهمة دفعية ببايثون) وبطريقة أخرى في التقديم (مثل خدمة بلغة Java)، فيتلقى النموذج مدخلات بمعنى مختلف. ولتفاديه اعتمد تعريفًا واحدًا مشتركًا للخصائص، مثل **مخزن الخصائص (feature store)** الذي يقدّم الخصائص نفسها دون اتصال (offline) للتدريب وفوريًا (online) للاستدلال. سجّل الخصائص الفورية وقارنها بالقيم المحسوبة دون اتصال.

12.4 استراتيجيات النشر (Deployment strategies)

الاستراتيجية	الطريقة	الغاية
النشر الظلي (Shadow)	يحسب النموذج الجديد درجات الحركة الحقيقية، لكن مخرجاته لا تُستخدم	التحقق على بيانات حية دون أي خطر على المستخدمين

الاستراتيجية	الطريقة	الغاية
نشر الكناري (Canary)	توجيه حصة صغيرة من الحركة (مثل 5%) إلى النموذج الجديد، ثم زيادتها تدريجيًا	حصر نطاق الضرر؛ والتراجع (roll back) بسرعة
الأزرق-الأخضر (Blue-green)	بيئتان كاملتان؛ وتحويل الحركة دفعة واحدة	تراجع فوري
A/B اختبار	تقسيم المستخدمين عشوائيًا ومقارنة المقاييس التجارية	قياس الأثر التجاري الحقيقي

12.5 المراقبة والانجراف (Monitoring and drift)

النوع	ما الذي يتغير	مثال	الاستجابة المعتادة
انجراف البيانات / (Data covariate drift)	$P(X)$: توزيع المدخلات	انضمام شريحة عملاء جديدة بعد حملة تسويقية	تحقق من الأمر؛ وأعد التدريب إذا انخفض الأداء
انجراف المفهوم (Concept drift)	$P(y X)$: العلاقة بين المدخلات والهدف	المحتالون يغيرون أساليبهم؛ فتصبح للخصائص نفسها دلالة مختلفة	أعد التدريب على بيانات حديثة؛ وراجع الخصائص
تحوّل التسميات / (Label prior shift)	$P(y)$: المعدل الأساسي (base rate)	ارتفاع انتشار الإنفلونزا في الشتاء مع بقاء الأعراض لكل حالة كما هي	أعد المعايرة أو عدّل العتبات

- **كشف الانجراف:** مؤشر PSI (مؤشر استقرار المجتمع population stability index؛ $0.1 < \text{مستقر}$ ، $0.1-0.25$ متوسط، $0.25 >$ كبير)، واختبار Kolmogorov–Smirnov للخصائص الرقمية، واختبار مربع كاي (chi-square) للخصائص الفئوية.
- **التسميات المتأخرة (Delayed labels):** حين تصل النتائج الحقيقية بعد أسابيع، راقب انجراف المدخلات وتوزيعات التنبؤات بوصفها إنذارات مبكرة.
- **المقاييس التشغيلية:** زمن الاستجابة (latency)، ومعدل الأخطاء، والإنتاجية (throughput)، والكلفة.
- **إعادة التدريب (Retraining):** مجدولة (مثلًا شهريًا) أو مُستتارة (بسبب انجراف أو تراجع في الأداء). اختر أرخص سياسة تُبقي الأداء فوق الحد المطلوب.
- **التنبيهات (Alerting):** ضع عتبات تستدعي تصرفًا فعليًا. فكثر التنبيهات تسبب إرهاق التنبيهات (alert fatigue).
- **حلقات التغذية الراجعة (Feedback loops):** قد تشكّل قرارات النموذج بيانات التدريب المستقبلية (مثلًا: القروض الموافق عليها وحدها تحصل على تسميات السداد). احتفظ بمجموعة صغيرة للاستكشاف العشوائي أو مجموعة ضابطة (control group).

12.6 التوسّع والكلفة

- **نماذج أصغر وأسرع:** التقطير (distillation): نموذج «طالب» صغير يتعلم من نموذج «معلم» كبير؛ والتكميم (quantization): أوزان بدقة عددية أقل؛ والتقليم (pruning).
- **التخزين المؤقت (Caching):** للتنبؤات المتكررة، وتجميع الطلبات في دفعات (batching).
- **فصل أبسط نموذج يلبي المتطلبات.** فمكسب 0.3% في الدقة الكلية نادرًا ما يبرر مضاعفة كلفة التقديم ثلاث مرات.

13.1 قابلية التفسير (Explainability)

- التفسيرات الشاملة (Global explanations): كيف يتصرف النموذج إجمالاً، مثل أهمية التبديل (permutation importance) أو مخططات ملخص SHAP.
- التفسيرات المحلية (Local explanations): لماذا صدر هذا التنبؤ تحديداً، مثل قيم SHAP أو LIME لعميل واحد. وهي ضرورية لتفسير القرارات الفردية مثل رفض طلب قرض.
- تحفظات: الأهمية ليست سببية، والخصائص المترابطة تتقاسم الأهمية أو تتوزعها فيما بينها، لذا بذلها كمجموعة واحدة.
- في القرارات المنظمة عالية المخاطر، يُفضل غالباً نموذج قابل للتفسير بطبيعته على تفسير صندوق أسود (black box) بعد وقوع القرار.

13.2 العدالة والتحيز (Fairness and bias)

- قد يدخل التحيز عبر البيانات التاريخية، أو العينات غير الممثلة، أو الخصائص البديلة (proxy features) كالرمز البريدي الذي يعمل بديلاً عن سمة محمية، أو عبر تعريفات التسميات.
- حذف السمة الحساسة لا يكفي، لأن البدائل تبقى. قس الأداء ومعدلات الخطأ لكل مجموعة.
- الفحوص الشائعة: التكافؤ الديموغرافي (demographic parity): معدلات إيجابية متقاربة؛ وتكافؤ الفرص (equal opportunity): استدعاء متقارب بين المجموعات. وقد تتعارض هذه المعايير، لذا اخترها بالتشاور مع أصحاب المصلحة.

13.3 الخصوصية وحماية البيانات

- تقليل البيانات (Data minimization): اجمع واحتفظ فقط بما يتطلبه الغرض.
- الموافقة وتقييد الغرض (Consent and purpose limitation): استخدم البيانات الشخصية فقط للأغراض التي وافق عليها أصحابها.
- الترميز المستعار (Pseudonymization) يستبدل المعرفات برموز، لكن البيانات تظل شخصية لأنه يمكن إعادة ربطها. أما إخفاء الهوية (Anonymization) فيزيل القدرة على التعرف على أي شخص. واحذر من إعادة التعرف (re-identification) عبر تركيبات من أشباه المعرفات (quasi-identifiers) مثل العمر والرمز البريدي والجنس.
- التحكم في الوصول والتشفير؛ ولا تضع أبداً أسراراً أو بيانات شخصية في السجلات (logs) أو في دفاتر (notebooks) تُشارك على نطاق واسع.
- التزم بالتنظيم المعمول به. وفي المملكة العربية السعودية هو نظام حماية البيانات الشخصية (PDPL).

13.4 الإشراف البشري والتوثيق

- الإنسان ضمن الحلقة (Human-in-the-loop) في القرارات عالية المخاطر: النموذج يربّط الأولويات أو يوصي، والإنسان يقرر، خاصة في الحالات منخفضة الثقة.
- بطاقات النماذج (Model cards) توثق الاستخدام المقصود، وبيانات التدريب، والأداء لكل مجموعة، والقيود، والاعتبارات الأخلاقية.

إجابات سريعة بنظرة واحدة عن القرارات الأكثر تكرارًا في أسئلة السيناريوهات.

14.1 أي مقياس؟

إذا قال السيناريو...	فكر في
تفويت حالة موجبة مكلف جدًا (مرض، احتيال، أعطال)	الاستدعاء (Recall)، أو F2
الإنذارات الكاذبة مكلفة جدًا (خطر العملاء، الرسائل المزعجة)	الضبط (Precision)، أو F0.5
كلا الخطأين مهم، والفئات غير متوازنة	PR-AUC، F1
لا يمكن التصرف إلا في أعلى k حالة	Precision@k، الرفع (lift)
جودة الترتيب بغض النظر عن عتبة القرار (threshold)	ROC-AUC (أو PR-AUC إذا كانت الحالات الموجبة نادرة)
الاحتمالات نفسها هي التي تُستخدم	الخسارة اللوغاريتمية (Log loss)، ومقياس Brier (Brier score)، ومنحنى المعايرة (calibration curve)
التكاليف محددة صراحة لكل FN و FP	التكلفة المتوقعة (Expected cost)؛ اختر ال threshold الذي يجعلها أقل ما يمكن
انحدار تكون فيه الأخطاء الكبيرة هي الأشد ضررًا	RMSE
انحدار تكلفة أخطائه خطية، مع وجود قيم شاذة	MAE (أو median absolute error إذا كانت السجلات تالفة)
الإدارة تريد الخطأ بالنسبة المئوية، ولا توجد قيم هدف تساوي صفرًا	MAPE / WAPE

14.2 أي نموذج؟

إذا قال السيناريو...	فكر في
يجب شرح القرارات للجهات التنظيمية أو للعملاء	الانحدار اللوجستي (Logistic regression)، شجرة ضحلة (shallow tree)، بطاقة تقييم (scorecard)
بيانات جدولية، وأعلى دقة ممكنة	التعزيز التدريجي (Gradient boosting)
خط أساس قوي بسرعة، مع ضبط قليل	الغابة العشوائية (Random forest) أو الانحدار اللوجستي
تصنيف نصوص قصيرة، مع مجموعة صغيرة من البيانات الموسومة	TF-IDF مع نموذج خطي؛ أو transformer مُدرَّب مسبقًا (pretrained)
صور بعدد قليل من الوسوم	التعلم بالنقل (Transfer learning) من CNN أو vision transformer مُدرَّب مسبقًا
لا توجد وسوم، والمطلوب إيجاد مجموعات	k-means (للمجموعات الكروية)، DBSCAN (للأشكال غير المنتظمة ومع الضوضاء)
شذوذات نادرة جدًا أو غير موسومة	Isolation Forest، كشف الشذوذ (anomaly detection)
مستخدمون جدد بلا سجل سابق	التوصية القائمة على المحتوى (Content-based) أو الرجوع إلى الأكثر شيوعًا (popularity fallback)؛ وهي مشكلة البدء البارد (cold start)

14.3 أي طريقة تحقق؟

استخدم	إذا كانت البيانات...
K-fold الطبقي (Stratified K-fold)	صفوفاً مستقلة، والفئات غير متوازنة
K-fold بالمجموعات (Group K-fold)	عدة صفوف لكل عميل أو مريض أو جهاز
تقسيم السلاسل الزمنية (Time-series split): التدريب على الماضي والتحقق على المستقبل	مرتبة زمنياً
التحقق المتقاطع المتداخل (Nested cross-validation)	صغيرة، والمطلوب ضبط النموذج وإعداد تقرير عن أدائه

14.4 أي معالجة مسبقة؟

الاختيار	الحالة
الترميز الأحادي (One-hot encoding)	فئة اسمية (nominal) بمستويات قليلة، مع نموذج خطي
ترميز الهدف (Target encoding) خارج الطيات (out-of-fold)، أو الترميز بالتردد (frequency)، أو التجزئة (hashing)	آلاف الفئات
الترميز الترتيبي (Ordinal encoding)	فئات مرتبة
RobustScaler أو التحويل اللوغاريتمي (log transform)	خصائص فيها قيم شاذة
لا حاجة إلى توحيد المقياس (scaling)	نموذج قائم على الأشجار
التعويض بالوسيط (Median imputation)، مع مؤشر للقيم المفقودة (missing indicator)	قيم مفقودة في خاصية رقمية ملتوية (skewed)
مؤشر للقيم المفقودة + دراسة المسألة من منظور المجال (domain investigation)	الفقد يعتمد على القيمة نفسها (MNAR)

14.5 تشخيص النموذج

الغرض	السبب المرجح	الإجراء
أداء التدريب مرتفع، والتحقق أقل منه بكثير	الإفراط في التوفيق (Overfitting)	التنظيم (Regularization)، تبسيط النموذج، بيانات أكثر، الإيقاف المبكر (early stopping)
أداء التدريب والتحقق منخفضان معاً	ضعف التوفيق (Underfitting)	نموذج أو خصائص أغنى
التحقق ممتاز، والأداء في الإنتاج ضعيف	تسرب البيانات (Leakage) أو اختلاف التدريب عن التشغيل (training-serving skew)	مراجعة الخصائص وخطوط المعالجة (pipelines)
الأداء يتراجع شهرياً بعد شهر	الانجراف (Drift)	المراقبة، إعادة التدريب، إعادة المعايرة
دقة كلية (accuracy) مرتفعة، واستدعاء (recall) منخفض للفئة النادرة	عدم توازن الفئات (Class imbalance)	أوزان الفئات (class weights)، ضبط الـ threshold، مقاييس PR
الـ AUC مستقر، لكن المعدل المنتبأ به بعيد عن الفعلي	تحويل توزيع الوسوم (Label shift) أو ضعف المعايرة (calibration)	إعادة المعايرة (Recalibrate)

- **الإيقاع:** نحو 90 ثانية لكل سؤال (140 سؤالاً في 3.5 ساعات). إذا تجاوز سؤال دقيقتين، ضع عليه علامة وانتقل إلى غيره.
- **اقرأ السطر الأخير أولاً** لتعرف المطلوب: الإجراء الأفضل (BEST)، أو ما يُفعل أولاً (FIRST)، أو السبب الأرجح (MOST likely). ثم امسح السيناريو بحثاً عن القيد الحاسم.
- **ابحث عن القيد الذي يحسم الإجابة:** قابلية التفسير (interpretability)، زمن الاستجابة (latency)، تكلفة السلي الكاذب (false negative) مقابل الموجب الكاذب (false positive)، عدم توازن الفئات، الترتيب الزمني، تكرار الكيانات نفسها، صغر البيانات، الخصوصية.
- **السيناريوهات الطويلة تحوي تفاصيل لا صلة لها بالسؤال** (أسماء الفرق، لوحات المتابعة، نوافذ الصيانة). تجاهلها.
- **ابدأ بالاستبعاد:** الإجابات التي تسرب البيانات، أو تمتس مجموعة الاختبار، أو تعتمد الدقة الكلية (accuracy) مع بيانات غير متوازنة، أو تتخطى خط الأساس (baseline)، تكون خاطئة في الغالب.
- **أسئلة «Select TWO» (اختر اثنين):** احكم على كل خيار وحده: صحيح أم خاطئ؟
- **لا تترك أي سؤال بلا إجابة.** ضع علامة، وخبّن، ثم عد إليه إن سمح الوقت.

المصطلح بالعربية	English	المعنى
اختبار أ/ب	A/B test	تجربة عشوائية تقارن بين نسختين
اختلاف التدريب عن التشغيل	Training-serving skew	حساب الخصائص بطريقة مختلفة بين التدريب والإنتاج
الاستدعاء / الحساسية	Recall	$TP / (TP + FN)$
الاستدلال / التنبؤ	Inference	استخدام نموذج مدرب لإصدار التنبؤات
الإفراط في التوفيق	Overfitting	حفظ بيانات التدريب بدل تعلم النمط؛ فيضعف التعميم
الانحياز	Bias (model)	خطأ ناتج عن افتراضات مفرطة في التبسيط
الإيقاف المبكر	Early stopping	إيقاف التدريب عندما يتوقف التحسن على بيانات التحقق
البواقي	Residual	القيمة الفعلية ناقص القيمة المتنبأ بها
التباين	Variance (model)	حساسية النموذج لعينة التدريب بعينها
التجميع العنقودي	Clustering	تجميع السجلات المتشابهة دون وسوم
التجميع بإعادة المعاينة	Bagging	تدريب عدة نماذج على عينات bootstrap ثم أخذ متوسط نتائجها
التحقق المتقاطع	Cross-validation	تقسيمات تدريب/تحقق متكررة للحصول على تقدير مستقر
الترميز	Encoding	تحويل الفئات إلى أرقام
التعزيز	Boosting	نماذج متتابعة يصحح كل منها أخطاء ما قبله
التقسيم الطبقي	Stratification	الحفاظ على نسب المجموعات عند التقسيم أو المعاينة
التنظيم	Regularization	عقوبة تحد من تعقيد النماذج
الخاصية / المتغير المستقل	Feature	متغير مُدخل يستخدمه النموذج
الدقة الكلية	Accuracy	نسبة التنبؤات الصحيحة من بين جميع التنبؤات
الضبط	Precision	$TP / (TP + FP)$
القيمة الاحتمالية	p-value	احتمال الحصول على بيانات بهذا القدر من التطرف إذا كانت H_0 صحيحة
القيمة الشاذة	Outlier	مشاهدة بعيدة عن بقية المشاهدات
المعامل الفائت	Hyperparameter	إعداد يُختار قبل التدريب (العمق، معدل التعلم)
المعايرة	Calibration	مدى تطابق الاحتمالات المتنبأ بها مع المعدلات الفعلية المرصودة
النماذج المجمعة	Ensemble	الجمع بين عدة نماذج
النوعية	Specificity	$TN / (TN + FP)$
الوسم / المتغير الهدف	Label	النتيجة التي يتعلم النموذج التنبؤ بها
انجراف البيانات	Data drift	تغير توزيع المدخلات مع مرور الوقت

المصطلح بالعربية	English	المعنى
انجراف المفهوم	Concept drift	تغيّر العلاقة بين المدخلات والمتغير الهدف
تحيز العينة	Sampling bias	عينة لا تمثل المجتمع الإحصائي
تسرّب البيانات	Data leakage	وصول معلومات إلى التدريب لا تكون متاحة وقت التنبؤ
تعويض القيم المفقودة	Imputation	ملء القيم المفقودة
تقليل الأبعاد	Dimensionality reduction	تمثيل البيانات بعدد أقل من الخصائص
توحيد المقياس	Scaling	وضع الخصائص ضمن نطاقات متقاربة
حفظ النموذج	Serialization	حفظ نموذج مدّرب في ملف
خط الأساس	Baseline	نموذج أو قاعدة بسيطة مرجعية يجب التفوق عليها
خط المعالجة	Pipeline	سلسلة من خطوات المعالجة المسبقة والنموذج تُدرّب معًا
ضعف التوفيق	Underfitting	نموذج أبسط من أن يلتقط النمط
عتبة القرار	Threshold	حدّ الاحتمال الذي يُعدّ التنبؤ عنده موجبًا
عدم توازن الفئات	Class imbalance	فئة أندر بكثير من الفئات الأخرى
فترة الثقة	Confidence interval	مدى يقيس عدم اليقين في تقدير ما
قابلية التفسير	Interpretability	مدى سهولة فهم البشر لقرارات النموذج
متغير مُربك	Confounder	متغير يؤثر في السبب والنتيجة معًا
مستودع الخصائص	Feature store	نظام مشترك يقدّم الخصائص نفسها للتدريب وللاستدلال
مصفوفة الارتباك	Confusion matrix	جدول يضم TP و FN و TN
معدل التعلّم	Learning rate	حجم الخطوة في كل تحديث أثناء التدريب